



POLSKO-JAPOŃSKA
AKADEMIA TECHNIK
KOMPUTEROWYCH

Wydział Informatyki

Katedra Baz Danych

Specjalizacja Systemy inteligentne i Data Science

Jakub Melzacki

Nr albumu s27664

**Predykcja wyników profesjonalnych meczów League
of Legends z wykorzystaniem systemów
rankingowych i metamodelu uczenia maszynowego**

Praca inżynierska

dr Dominik Deja

Warszawa, maj 2026

Streszczenie

Praca dotyczy predykcji wyników profesjonalnych meczów *League of Legends* na podstawie historycznych danych sportowych oraz porównania jakości predykcji z benchmarkiem bukmacherskim. Wykorzystano dane GOL.GG oraz kursy z serwisu OddsPortal. Celem pracy było sprawdzenie, czy systemy rankingowe zawodników i drużyn mogą stanowić skuteczną bazę predykcyjną oraz czy metamodel rankingowo-kontekstowy poprawia jakość oceny wyniku meczu.

Porównano rodziny rankingów Elo, Glicko-2, TrueSkill, OpenSkill, Plackett–Luce oraz Thurstone–Mosteller. Ich predykcje, miary niepewności, pełny historyczny kontekst drużynowy W20 oraz sygnały skorygowane dwumianowo względem formatu serii wykorzystano w metamodelu W20-Binomial. Hiperparametry kilku rodzin estymatorów dobrano z użyciem Optuna, a finalne warianty oceniono chronologicznie w procedurze walk-forward, z użyciem metryk AUC, LogLoss, Brier score i ECE.

Wyniki wskazują, że modele zawodnicze są skuteczniejsze od modeli opartych wyłącznie na nazwach drużyn, a najlepszym pojedynczym rankingiem był Player Glicko-2. Najlepszym estymatorem finalnego zestawu cech okazała się regularyzowana regresja logistyczna ElasticNet. Wariant końcowy został dodatkowo usymetryzowany względem kolejności drużyn oraz skalibrowany metodą Platt’a w schemacie expanding-window. Skalibrowany symetryczny model LR-ElasticNet-W20-Binomial uzyskał niższy LogLoss niż pojedynczy ranking Player Glicko-2 oraz benchmarki Market Open i Market Close. Wynik należy interpretować jako przewagę predykcyjną na analizowanej próbie historycznej, a nie jako dowód opłacalności strategii zakładów.

Słowa kluczowe: League of Legends, esport, predykcja wyników, systemy rankingowe, Glicko-2, metamodel kontekstowy, W20-Binomial, regresja logistyczna ElasticNet, kursy bukmacherskie, LogLoss, kalibracja.

Abstract

This thesis addresses the problem of predicting outcomes of professional *League of Legends* matches using historical sports data and compares the quality of these predictions with bookmaker benchmarks. The study uses GOL.GG data and betting odds collected from OddsPortal. The objective was to examine whether player- and team-based rating systems can provide an effective predictive foundation, and whether a ranking-context metamodel improves probabilistic match outcome estimation.

The analysis compares Elo, Glicko-2, TrueSkill, OpenSkill, Plackett–Luce and Thurstone–Mosteller rating families. Their predictions, uncertainty measures, full historical team context with a 20-match rolling window, and binomially adjusted signals dependent on series format were used in the W20-Binomial metamodel. Hyperparameters of several estimator families were selected with Optuna, while final variants were evaluated chronologically using a walk-forward procedure and the AUC, LogLoss, Brier score and ECE metrics.

The results indicate that player-based models outperform models based only on team names, and that Player Glicko-2 was the strongest single rating system. The best estimator for the final feature set was regularized ElasticNet logistic regression. The final variant was additionally symmetrized with respect to team ordering and calibrated with expanding-window Platt scaling. The calibrated symmetric LR-ElasticNet-W20-Binomial model achieved lower LogLoss than the single Player Glicko-2 ranking and the Market Open and Market Close bookmaker benchmarks. This result should be interpreted as a predictive advantage on the analysed historical sample, not as evidence of profitability of a betting strategy.

Keywords: League of Legends, esports, match outcome prediction, rating systems, Glicko-2, contextual metamodel, W20-Binomial, ElasticNet logistic regression, betting odds, LogLoss, calibration.

Spis treści

1	Wstęp	1
2	Stan wiedzy i kontekst problemu	3
2.1	Predykcja wyników w sporcie i esporcie	3
2.1.1	Od klasyfikacji zwycięzcy do predykcji probabilistycznej	3
2.1.2	Dominujący charakter prac dotyczących <i>League of Legends</i>	3
2.1.3	Specyfika esportu i uzasadnienie ratingów zawodniczych	4
2.2	Systemy rankingowe jako modele siły uczestników	5
2.2.1	Elo jako punkt wyjścia dla modeli ratingowych	5
2.2.2	Elo w predykcji piłki nożnej	5
2.2.3	Rozszerzenia probabilistyczne: Glicko-2, TrueSkill i OpenSkill	5
2.3	Prace łączące ratingi z kursami bukmacherskimi	6
2.3.1	Ratingi i regresja logistyczna	6
2.3.2	Betting Odds Rating System	6
2.4	Metamodelowanie i łączenie sygnałów	7
2.4.1	Stacking jako rama metodologiczna	7
2.5	Ocena probabilistyczna i kalibracja	8
2.5.1	Właściwe reguły punktacji	8
2.5.2	Kalibracja prawdopodobieństw	8
2.6	Wnioski dla niniejszej pracy	8
3	Dane i opis zjawiska	10
3.1	Charakterystyka środowiska League of Legends	10
3.2	Dlaczego profesjonalne League of Legends?	11
3.3	Źródła danych	11
3.4	Zakres informacyjny danych sportowych	13
3.5	Zakres informacyjny danych bukmacherskich	14
3.6	Definicja problemu predykcyjnego	15
3.7	Kursy bukmacherskie jako benchmark probabilistyczny	15
3.8	Przygotowanie i dopasowanie danych	16
3.9	Braki danych i ograniczenia próby	17

3.10	Zasady unikania przecieku informacji	18
3.11	Uzasadnienie wyboru głównej próbki ewaluacyjnej	18
4	Eksploracyjna analiza danych	19
4.1	Cel analizy eksploracyjnej	19
4.2	Zakres czasowy i charakter próbki	19
4.3	Zmienna objaśniana i balans klas	21
4.4	Formaty meczów	22
4.5	Poziom rozgrywek	23
4.6	Rynek bukmacherski jako punkt odniesienia	24
4.7	Historyczne statystyki gry jako źródło kontekstu	27
4.8	Obserwacje nietypowe i konsekwencje dla modelowania	30
4.9	Wnioski z analizy eksploracyjnej	30
5	Metodyka oceny modeli	31
5.1	Cel rozdziału	31
5.2	Wspólna próba ewaluacyjna	31
5.3	Zasada chronologicznej walidacji	32
5.4	Bootstrap blokowy dla porównania modeli	32
5.5	Metryki oceny	33
5.5.1	LogLoss	33
5.5.2	AUC	34
5.5.3	Brier Score	34
5.5.4	ECE	34
5.5.5	Accuracy	34
5.6	Hierarchia wyboru modelu	35
5.7	Konsekwencje dla interpretacji wyników	36
6	Systemy rankingowe jako modele bazowe	37
6.1	Rola systemów rankingowych w predykcji	37
6.2	Ranking drużynowy i ranking zawodniczy	37
6.3	Zastosowane rodziny rankingów	38
6.3.1	Elo	38
6.3.2	Glicko-2	38
6.3.3	TrueSkill i OpenSkill	38
6.3.4	Modele porównawcze	39
6.4	Procedura obliczania predykcji rankingowych	39
6.5	Dobór parametrów systemów rankingowych	39
6.6	Wyniki po doborze parametrów	40
6.7	Porównanie ratingów z benchmarkiem rynkowym	41

6.8	Znaczenie wyników rankingowych dla dalszego modelowania	43
7	Metamodel kontekstowy W20-Binomial	44
7.1	Motywacja budowy metamodelu	44
7.1.1	Rola modelu drugiego poziomu	44
7.1.1.1	Ograniczenia pojedynczych rankingów	44
7.1.1.2	Stacking jako uzasadnienie konstrukcji modelu	44
7.1.2	Definicja wariantu W20-Binomial	44
7.2	Zestaw cech W20-Binomial	45
7.2.1	Predykcje rankingowe zawodników	45
7.2.2	Niepewność ocen i rozkład siły składu	45
7.2.3	Historyczny kontekst drużynowy W20	45
7.2.4	Cechy dwumianowe dla formatu serii	46
7.3	Współzależność sygnałów rankingowych	49
7.3.1	Korelacje pomiędzy rodzinami rankingów	49
7.3.2	Analiza VIF i konsekwencje dla modelu liniowego	49
7.4	Dobór długości okna historycznego	50
7.5	Dobór rodziny estymatora po strojeniu hiperparametrów	51
7.6	Ablacje finalnego estymatora: masking i sygnał Glicko-2	52
7.7	Symetryzacja kolejności drużyn	54
7.7.1	Źródło asymetrii technicznej	54
7.7.2	Procedura uśredniania predykcji	54
7.8	Kalibracja prawdopodobieństw	55
7.8.1	Schemat expanding-windows	55
7.8.2	Porównanie Platta i kalibracji izotonicznej	55
7.9	Wnioski z etapu metamodelowania	57
8	Ocena końcowa i porównanie z rynkiem bukmacherskim	58
8.1	Cel porównania końcowego	58
8.1.1	Zakres ewaluacji	58
8.1.1.1	Wspólna próba sportowo-rynkowa	58
8.1.1.2	Predykcja probabilistyczna zamiast decyzji finansowej	58
8.2	Porównywane warianty	58
8.2.1	Model finalny i warianty kontrolne	58
8.2.1.1	Sym-Cal jako wariant promowany	58
8.2.1.2	Znaczenie kursu otwarcia i zamknięcia	59
8.3	Wyniki na wspólnej próbie	59
8.3.1	Główna tabela metryk	59
8.3.1.1	Jednolity zbiór obserwacji	59
8.3.1.2	Interpretacja przewagi LogLoss	60

8.4	Istotność różnic LogLoss	61
8.4.1	Definicja różnicy strat	61
8.4.2	Przedziały ufności bootstrapu blokowego	62
8.4.3	AUC jako metryka pomocnicza	62
8.5	Analiza segmentowa według formatu serii	63
8.5.1	Definicja przewagi segmentowej	63
8.5.2	Wyniki segmentowe	64
8.5.2.1	LogLoss według długości serii	64
8.5.2.2	Ostrożność interpretacji segmentu Bo5	64
8.6	Znaczenie kalibracji	64
8.6.1	Porównanie surowego i skalibrowanego modelu	64
8.6.1.1	Wpływ na LogLoss i ECE	64
8.6.1.2	Dlaczego ECE nie jest jedynym kryterium	65
8.7	Weryfikacja hipotez badawczych	65
8.7.1	Tabela weryfikacyjna	65
8.7.2	Interpretacja hipotezy rynkowej	66
8.8	Wnioski z porównania końcowego	66
8.8.1	Syntetyczna odpowiedź empiryczna	66
8.8.1.1	Przewaga predykcyjna modelu Sym-Cal	66
8.8.1.2	Ograniczenie interpretacji rynkowej	66
9	Dyskusja	68
9.1	Interpretacja najważniejszych wyników	68
9.1.1	Znaczenie modelowania na poziomie zawodników	68
9.1.2	Rola metamodelu W20-Binomial	68
9.1.3	Symetryzacja i kalibracja jako końcowe uporządkowanie modelu	69
9.2	Interpretacja porównania z rynkiem bukmacherskim	69
9.2.1	Rynek jako silny benchmark probabilistyczny	69
9.2.2	Granice wniosku rynkowego	70
9.3	Ograniczenia badania	70
9.3.1	Zakres i reprezentatywność danych	70
9.3.2	Dryf czasowy i zmiany środowiska gry	70
9.3.3	Ograniczenia konstrukcji cech	71
9.4	Implikacje dla dalszych badań	71
9.4.1	Rozszerzenie danych przedmeczowych	71
9.4.2	Walidacja przyszłościowa	71
9.4.3	Lepsze modelowanie składu i synergii	71
9.5	Podsumowanie dyskusji	72

10 Zakończenie	73
10.1 Podsumowanie celu pracy	73
10.2 Najważniejsze wyniki	73
10.3 Weryfikacja hipotez	74
10.4 Odpowiedź na pytanie badawcze	74

Rozdział 1

Wstęp

Dynamiczny rozwój esportu sprawił, że profesjonalne rozgrywki w grach komputerowych stały się pełnoprawnym obszarem analizy ilościowej. Jednym z najgłośniejszych przykładów jest *League of Legends*, dla którego dostępne są wieloletnie dane o meczach, składach, statystykach gry oraz – dla części spotkań – kursach bukmacherskich. Taka kombinacja danych pozwala badać nie tylko to, czy model potrafi wskazać zwycięzcę, lecz także czy potrafi przypisać realistyczne prawdopodobieństwo wyniku.

Prognozowanie wyników takich meczów jest trudne, ponieważ obserwowana siła zespołu zmienia się w czasie. Składy są przebudowywane, zawodnicy pełnią wyspecjalizowane role, a aktualizacje gry wpływają na dominujące strategie. Dlatego sama historyczna nazwa drużyny jest często zbyt ubogą reprezentacją jej bieżącego potencjału sportowego. W pracy przyjęto więc perspektywę przedmeczowej predykcji probabilistycznej, w której model może korzystać wyłącznie z informacji dostępnych przed rozpoczęciem spotkania.

Celem niniejszej pracy jest opracowanie oraz ocena modelu przewidującego wynik profesjonalnego meczu *League of Legends*. Model łączy systemy rankingowe zawodników, miary niepewności, pełny historyczny kontekst drużynowy W20 oraz korektę dwumianową zależną od formatu serii Bo1/Bo3/Bo5. Jako zewnętrzny punkt odniesienia wykorzystano prawdopodobieństwa implikowane przez kursy bukmacherskie, które są jednym z najsilniejszych publicznie dostępnych benchmarków dla predykcji przedmeczowej.

Praca nie dotyczy budowy systemu inwestycyjnego ani oceny opłacalności zakładów. Analiza ogranicza się do jakości predykcji probabilistycznej, dlatego wykorzystano AUC, LogLoss, Brier Score oraz Expected Calibration Error, przy czym główną metryką jest LogLoss.

Zakres pracy obejmuje analizę danych GOL.GG, przygotowanie wspólnej próby z kursami OddsPortal, porównanie systemów rankingowych, budowę metamodelu W20-Binomial oraz końcową ocenę względem rynku bukmacherskiego. Główna ewaluacja została przeprowadzona na meczach, dla których dostępne były oba typy danych.

Główne pytanie badawcze pracy brzmi: czy model oparty na rankingach zawodników i historycznym kontekście drużyn potrafi skutecznie przewidywać wyniki profesjonalnych

meczów *League of Legends* oraz osiągać jakość probabilistyczną konkurencyjną względem kursów bukmacherskich?

W pracy przyjęto następujące hipotezy badawcze:

1. Systemy rankingowe oparte na zawodnikach osiągają lepszą jakość predykcji niż systemy rankingowe oparte wyłącznie na drużynach.
2. Metamodel łączący sygnały rankingowe poprawia jakość predykcji względem pojedynczego najlepszego systemu rankingowego.
3. Dodanie historycznego kontekstu formy drużyn poprawia jakość probabilistyczną modelu względem wariantu opartego wyłącznie na rankingach.
4. Model rankingowo-kontekstowy osiąga wyniki konkurencyjne względem prawdopodobieństw implikowanych przez kursy bukmacherskie.

Dalsza część pracy została zorganizowana w następujący sposób. Najpierw przedstawiono stan wiedzy i kontekst problemu, obejmujący predykcję sportową, systemy rankingowe, metamodelowanie, ocenę probabilistyczną oraz rolę kursów bukmacherskich jako benchmarku. Następnie opisano środowisko *League of Legends*, wykorzystane źródła danych GOL.GG i OddsPortal oraz proces konstrukcji wspólnej próby badawczej. Kolejny rozdział zawiera eksploracyjną analizę danych, obejmującą strukturę zbioru, formaty meczów, poziomy rozgrywek oraz podstawową analizę rynku bukmacherskiego. W dalszej części opisano metodykę ewaluacji, systemy rankingowe wykorzystane jako modele bazowe, konstrukcję metamodelu W20-Binomial, dobór okna historycznego, porównanie rodzin estymatorów oraz końcową symetryzację i kalibrację. Rozdział wynikowy prezentuje końcowe porównanie modeli, analizę bootstrapową, segmentację według formatu serii i weryfikację hipotez. Następnie omówiono interpretację wyników, ograniczenia badania oraz kierunki dalszych prac. Ostatni rozdział zawiera syntetyczne podsumowanie i odpowiedź na pytanie badawcze.

Rozdział 2

Stan wiedzy i kontekst problemu

2.1 Predykcja wyników w sporcie i esporcie

2.1.1 Od klasyfikacji zwycięzcy do predykcji probabilistycznej

Predykcja wyniku meczu sportowego może być formułowana na kilka sposobów. Najprostszym wariantem jest klasyfikacja zwycięzcy, w której model zwraca jedną z klas. W niniejszej pracy problem jest jednak rozumiany szerzej: celem nie jest wyłącznie wskazanie bardziej prawdopodobnego zwycięzcy, lecz oszacowanie prawdopodobieństwa zwycięstwa jednej ze stron. Takie ujęcie jest istotne, ponieważ dwa modele o podobnej trafności klasyfikacyjnej mogą różnić się jakością przypisywanych prawdopodobieństw. Model może poprawnie porządkować mecze według faworyta, ale jednocześnie systematycznie zawyżać lub zaniżać pewność predykcji.

W zadaniach sportowych i esportowych probabilistyczna interpretacja wyniku ma szczególne znaczenie. Mecz jest zdarzeniem losowym zależnym od aktualnej dyspozycji zawodników, zmian składu, decyzji strategicznych, przewagi strony mapy, formatu serii oraz czynników niedostępnych w danych historycznych. Model, który przypisuje zbyt wysoką pewność pojedynczym predykcjom, może osiągać akceptowalną trafność, ale słabą jakość probabilistyczną. Dlatego w dalszej części pracy główną metryką jest LogLoss, a accuracy pełni co najwyżej rolę pomocniczą.

2.1.2 Dominujący charakter prac dotyczących *League of Legends*

Literatura dotycząca predykcji w *League of Legends* jest relatywnie młoda i w dużej części koncentruje się na informacjach dostępnych w trakcie gry albo na cechach blisko związanych z przebiegiem konkretnej mapy. Przykładowo prace dotyczące predykcji wyniku meczu, analizy cech zwycięstwa, doświadczenia graczy na bohaterach oraz predykcji w czasie rzeczywistym wykorzystują statystyki drużyn, wybory bohaterów, doświadczenie

zawodników lub zmienne opisujące stan rozgrywki (L. Lin 2016; Costa i in. 2021; Do i in. 2021; Junior i Campelo 2023). Taki kierunek jest naturalny, ponieważ dane wewnątrz gry silnie opisują aktualną przewagę jednej ze stron.

Z perspektywy niniejszej pracy jest to jednak inny problem badawczy niż przedmeczowa predykcja probabilistyczna. Jeżeli model korzysta z informacji po rozpoczęciu mapy, takich jak złoto, zabójstwa, obiekty neutralne, kompozycje po drafcie albo bieżący stan mapy, to przewiduje wynik warunkowo względem już ujawnionej części meczu. W niniejszej pracy przyjęto ostrzejsze ograniczenie informacyjne: model powinien działać przed meczem, a więc bez znajomości przebiegu gry. Oznacza to, że większe znaczenie mają historyczna siła zawodników, skład drużyny, forma, region, liga, format serii oraz kontekst czasowy.

Ten podział wyznacza lukę badawczą. Istnieją prace analizujące *League of Legends* i istnieją prace wykorzystujące systemy rankingowe w sporcie, ale znacznie rzadziej spotyka się połączenie: przedmeczowa predykcja profesjonalnych spotkań *League of Legends*, ratingi liczone sekwencyjnie, metamodel probabilistyczny oraz porównanie z benchmarkiem rynku kursów. Niniejsza praca wpisuje się właśnie w tę lukę.

2.1.3 Specyfika esportu i uzasadnienie ratingów zawodniczych

Esport różni się od tradycyjnych dyscyplin sportowych kilkoma cechami istotnymi dla modelowania. Po pierwsze, środowisko gry zmienia się wraz z aktualizacjami, które mogą wpływać na wartość strategii, bohaterów i stylów gry. Po drugie, drużyny często modyfikują składy pomiędzy sezonami, a pojedynczy zawodnik może mieć duży wpływ na siłę zespołu. Po trzecie, profesjonalne rozgrywki są podzielone na ligi, turnieje i regiony o różnym poziomie sportowym. Te czynniki powodują, że model oparty wyłącznie na nazwie drużyny może być niestabilny, szczególnie przy transferach zawodników.

Z tego powodu uzasadnione jest wykorzystanie rankingów zawodniczych jako podstawowego sygnału. Ranking zawodnika może przenosić część informacji pomiędzy drużynami po transferze i pozwala oddzielić bieżącą siłę składu od historycznej marki organizacji. Jednocześnie ranking sam w sobie nie opisuje pełnego kontekstu meczu: nie zawiera bezpośrednio informacji o formie w ostatnich spotkaniach, stylu gry, ekonomii, czasie trwania map ani formacie serii. Te ograniczenia motywują budowę metamodelu łączącego rankingi z historycznymi agregatami drużynowymi.

2.2 Systemy rankingowe jako modele siły uczestników

2.2.1 Elo jako punkt wyjścia dla modeli ratingowych

Jednym z najbardziej znanych sposobów modelowania siły uczestników rywalizacji jest system Elo, pierwotnie zaproponowany dla szachów (Elo 1978). Podstawowa idea polega na przypisaniu każdemu graczowi liczbowej oceny siły, która jest aktualizowana po kolejnych wynikach. Różnica ratingów jest przekształcana na oczekiwane prawdopodobieństwo zwycięstwa, a następnie ratingi są korygowane zależnie od tego, czy wynik był zgodny z oczekiwaniem.

Popularność Elo wynika z prostoty, interpretowalności i możliwości działania online. Model nie wymaga pełnego ponownego trenowania po każdym meczu, lecz aktualizuje oceny sekwencyjnie. Ta cecha jest szczególnie użyteczna w danych sportowych i esportowych, gdzie obserwacje pojawiają się chronologicznie, a siła uczestników może zmieniać się w czasie.

2.2.2 Elo w predykcji piłki nożnej

Zastosowanie Elo do piłki nożnej badali między innymi Hvattum i Arntzen (Hvattum i Arntzen 2010). Autorzy wykorzystali ratingi Elo jako źródło zmiennych w uporządkowanych modelach logitowych predykcji wyniku meczu. Istotne jest tutaj nie samo użycie rankingu jako tabeli siły zespołów, lecz przekształcenie różnicy ratingów w predykcję probabilistyczną i porównanie takiego podejścia z innymi metodami.

Wyniki tej pracy są ważnym argumentem metodologicznym dla niniejszego projektu. Pokazują, że rating historyczny może być używany jako sygnał predykcyjny w modelu statystycznym, a nie tylko jako opisowa miara pozycji drużyny. Jednocześnie późniejsze omówienia tego nurtu wskazują, że modele oparte wyłącznie na Elo mogą być słabsze od kursów bukmacherskich, które agregują więcej informacji rynkowej (Wunderlich i Memmert 2018). Wniosek dla niniejszej pracy jest następujący: ratingi są silnym, interpretowalnym punktem wyjścia, ale nie powinny być traktowane jako pełny opis meczu. Dlatego w dalszych rozdziałach ratingi są porównywane jako samodzielne benchmarki, a następnie używane jako cechy metamodelu.

2.2.3 Rozszerzenia probabilistyczne: Glicko-2, TrueSkill i OpenSkill

Klasyczny Elo reprezentuje siłę jedną liczbą, ale nie opisuje jawnie niepewności tej oceny. W praktyce dwie drużyny lub dwóch zawodników z takim samym ratingiem mogą różnić się wiarygodnością oszacowania: jedna ocena może wynikać z wielu aktualnych

meczów, a druga z małej liczby starych obserwacji. System Glicko oraz jego rozwinięcie Glicko-2 dodają do ratingu miarę niepewności, dzięki czemu aktualizacja może zależeć od pewności ocen uczestników (Glickman 1995; Glickman 2012).

Inną rodziną metod są bayesowskie systemy ratingowe, takie jak TrueSkill (Herbrich, Minka i Graepel 2007), algorytmy online opisane przez Wenga i Lina (Weng i C.-J. Lin 2011) oraz OpenSkill (Joshy 2024). Ich wspólną cechą jest traktowanie siły uczestnika jako zmiennej losowej, a nie pojedynczej deterministycznej wartości. Taka reprezentacja jest atrakcyjna w esporcie, ponieważ pozwala modelowi odróżnić drużyny stabilne od drużyn, których poziom jest słabo rozpoznany.

W niniejszej pracy ratingi nie są traktowane wyłącznie jako końcowe modele. Pełnią dwie role. Po pierwsze, są oceniane jako samodzielne benchmarki predykcyjne. Po drugie, ich predykcje i parametry, w tym miary niepewności, stają się wejściem metamodelu. Takie podejście zachowuje interpretowalność rankingów, a jednocześnie pozwala modelowi wyższego poziomu łączyć wiele powiązanych sygnałów.

2.3 Prace łączące ratingi z kursami bukmacherskimi

2.3.1 Ratingi i regresja logistyczna

Prace sportowe oparte na ratingach są ważnym punktem odniesienia, ponieważ analizują podobną strukturę problemu: siła uczestników zmienia się w czasie, predykcja musi być wykonywana przed meczem, a wynik jest oceniany probabilistycznie. Thegelström (Thegelström 2023) analizował zastosowanie systemu Elo oraz regresji logistycznej do prognozowania kursów Premier League. Z perspektywy niniejszej pracy istotne są trzy elementy tego podejścia: rating jest aktualizowany chronologicznie, różnica ratingów staje się wejściem modelu statystycznego, a wyniki są interpretowane w odniesieniu do rynku kursów.

Podobieństwo do niniejszej pracy dotyczy więc ogólnej architektury: rating sekwencyjny + model probabilistyczny + benchmark rynkowy. Różnice są jednak równie ważne. W niniejszym projekcie ratingi są liczone nie tylko na poziomie drużyn, lecz także na poziomie zawodników, co jest uzasadnione transferami i rolami w *League of Legends*. Ponadto końcowy model nie wykorzystuje pojedynczego ratingu, lecz łączy wiele rodzin rankingów, miary niepewności oraz kontekst historyczny W20.

2.3.2 Betting Odds Rating System

Najbardziej bezpośrednim przykładem połączenia ratingów i kursów jest praca Wunderlicha i Memmerta (Wunderlich i Memmert 2018). Autorzy zaproponowali Betting Odds Rating System, w którym informacje zawarte w kursach są wykorzystywane do aktualizacji oceny siły drużyn. Badanie objęło 14931 meczów z sezonów 2007/2008–2016/2017

w kilku rozgrywkach piłkarskich: Premier League, Bundeslidze, La Liga, Serie A oraz europejskich pucharach. Kursy zostały znormalizowane w celu usunięcia marży bukmacherskiej, a następnie porównano kilka wariantów: klasyczny model oparty na wyniku, wariant uwzględniający bramki oraz wariant oparty na kursach.

Wyniki pokazały, że kursy bukmacherskie były najsilniejszym punktem odniesienia pod względem średniej straty informacyjnej: dla samych kursów raportowano wartość 1.380, dla ELO-Odds 1.391, dla ELO-Goals 1.401, a dla ELO-Result 1.403. Oznacza to, że wariant wykorzystujący informację z kursów był lepszy od wariantów aktualizowanych wyłącznie wynikiem lub bramkami, ale nadal nie przewyższył bezpośrednio samych kursów jako prognozy. Dla niniejszej pracy jest to ważne ostrzeżenie: rynek kursów jest bardzo silnym benchmarkiem probabilistycznym, więc przewaga nad nim wymaga starannej ewaluacji na wspólnej próbie i z kontrolą niepewności.

Autorzy podkreślają również różnicę pomiędzy jakością predykcijną a strategią finansową. Model może być użyteczny jako probabilistyczny opis siły drużyn, nawet jeśli nie tworzy bezpośrednio opłacalnej strategii zakładów. Ten wniosek jest zgodny z zakresem niniejszej pracy: kursy są traktowane jako benchmark prawdopodobieństw, a nie jako punkt wyjścia do analizy zysku, stawek lub zarządzania kapitałem.

2.4 Metamodelowanie i łączenie sygnałów

2.4.1 Stacking jako rama metodologiczna

Pojedynczy ranking może dobrze opisywać relatywną siłę zawodników, ale zwykle pomija część kontekstu. Z drugiej strony cechy historyczne drużyny mogą zawierać informacje o stylu gry i formie, lecz są podatne na szum oraz zmiany składu. Naturalnym rozwiązaniem jest połączenie wielu źródeł informacji w modelu drugiego poziomu.

Podejście to jest zgodne z ideą stacked generalization (Wolpert 1992) oraz stacked regressions (Breiman 1996). W takim schemacie predykcje modeli bazowych mogą być traktowane jako cechy wejściowe dla metamodelu. W niniejszej pracy model drugiego poziomu nie zastępuje rankingów, lecz uczy się, jak łączyć ich predykcje, niepewności oraz kontekst historyczny W20.

Wybór regresji logistycznej ElasticNet jako finalnego estymatora jest zgodny z charakterem problemu. Cechy rankingowe są silnie skorelowane, ponieważ wiele systemów opisuje tę samą ukrytą siłę sportową. Regularyzacja pozwala ograniczyć niestabilność współczynników i zmniejszyć ryzyko przeuczenia, a jednocześnie zachowuje większą interpretowalność niż modele drzewiaste lub głębokie sieci neuronowe.

2.5 Ocena probabilistyczna i kalibracja

2.5.1 Właściwe reguły punktacji

Ponieważ celem pracy jest oszacowanie prawdopodobieństwa zwycięstwa, metryka oceny powinna nagradzać poprawne prawdopodobieństwa, a nie tylko poprawną klasę. LogLoss oraz Brier Score należą do rodziny reguł punktacji używanych do oceny prognoz probabilistycznych. Właściwe reguły punktacji zachęcają model do raportowania prawdziwych przekonań probabilistycznych, ponieważ zaniżanie lub zawyżanie pewności jest karane (Gneiting i Raftery 2007).

LogLoss jest szczególnie istotny, ponieważ silnie karze sytuacje, w których model przypisuje wysokie prawdopodobieństwo błędnemu wynikowi. Jest to pożądane w analizie przedmeczowej, gdzie nadmierna pewność może być bardziej szkodliwa niż umiarkowana niepewność. Brier Score pełni funkcję pomocniczą, ponieważ mierzy średni kwadratowy błąd prawdopodobieństwa. AUC ocenia zdolność rozróżniania meczów, ale nie wystarcza do oceny jakości samych prawdopodobieństw.

2.5.2 Kalibracja prawdopodobieństw

Model może dobrze porządkować obserwacje, ale nadal generować źle skalibrowane prawdopodobieństwa. Kalibracja oznacza zgodność pomiędzy deklarowanym prawdopodobieństwem a empiryczną częstością zdarzenia. Jeżeli model w grupie predykcji około 70% wygrywa w rzeczywistości tylko w 60% przypadków, to jest nadmiernie pewny.

Do klasycznych metod poprawy kalibracji należą skalowanie Platt'a i kalibracja izotoniczna (Zadrozny i Elkan 2002; Niculescu-Mizil i Caruana 2005). W nowszej literaturze zwraca się również uwagę, że modele o wysokiej trafności mogą być słabo skalibrowane, dlatego kalibracja powinna być analizowana osobno (Guo i in. 2017). W niniejszej pracy kalibracja jest wykonywana w schemacie expanding-window, aby uniknąć przecieku informacji z przyszłości.

2.6 Wnioski dla niniejszej pracy

Przegląd literatury prowadzi do kilku decyzji projektowych. Po pierwsze, w pracach dotyczących *League of Legends* dominują zadania wykorzystujące informacje dostępne w trakcie gry lub po jej rozpoczęciu, dlatego przedmeczowa predykcja probabilistyczna wymaga osobnego ujęcia. Po drugie, systemy rankingowe są naturalnym punktem wyjścia, ponieważ umożliwiają sekwencyjne śledzenie zmiennej siły zawodników i drużyn. Po trzecie, ratingi powinny być analizowane probabilistycznie, a nie wyłącznie jako ranking porządkowy. Po czwarte, kursy bukmacherskie są silnym benchmarkiem, ale ich użycie w tej pracy dotyczy jakości prawdopodobieństw, a nie strategii finansowej. Po piąte, me-

tamodelowanie pozwala połączyć wiele rodzin rankingów z kontekstem historycznym, co odpowiada złożoności profesjonalnego esportu.

Te założenia wyznaczają dalszą strukturę pracy. Kolejne rozdziały opisują dane GOL.GG i OddsPortal, eksploracyjną analizę danych, metodykę ewaluacji, systemy rankingowe, konstrukcję metamodelu oraz końcowe porównanie z benchmarkami rynkowymi.

Rozdział 3

Dane i opis zjawiska

3.1 Charakterystyka środowiska League of Legends

League of Legends jest drużynową grą strategiczną typu MOBA, w której dwa pięcio-osobowe zespoły rywalizują na symetrycznej mapie. Celem gry jest zniszczenie głównej struktury przeciwnika, ale droga do tego celu obejmuje wiele mierzalnych elementów: kontrolę zasobów, przewagę ekonomiczną, walki drużynowe, niszczenie wież, zdobywanie smoków i Baronów oraz wykorzystanie indywidualnych umiejętności zawodników. Z perspektywy tej pracy najważniejsze jest to, że część tych informacji można obserwować historycznie i przekształcać w cechy opisujące styl oraz formę drużyny przed kolejnym meczem.

Profesjonalny mecz może być rozgrywany jako pojedyncza gra Bo1 albo jako seria Bo3 lub Bo5. Format serii ma znaczenie probabilistyczne: w dłuższej serii przypadkowy wynik jednej mapy ma mniejszy wpływ na końcowe rozstrzygnięcie niż w Bo1. Z tego powodu format meczu nie jest w pracy traktowany wyłącznie jako opis organizacyjny, lecz jako informacja strukturalna wykorzystywana później w modelu W20-Binomial.

Rozgrywki odbywają się w wielu regionach i na różnych poziomach sportowych. Obok lig najwyższego szczebla, takich jak LCK, LPL, LEC i LCS, występują ligi regionalne, akademickie oraz turnieje międzynarodowe. Taki zbiór danych daje nam dużą wariancję poziomów rozgrywek, oraz bogatszy zbiór do uczenia modelu.

Istotną cechą środowiska jest również zmienność w czasie. Aktualizacje gry wpływają na siłę postaci, tempo rozgrywki i opłacalność strategii, a transfery zawodników zmieniają realną siłę drużyn. Konsekwencją dla modelowania jest konieczność chronologicznego przetwarzania danych, oraz szybkie adaptoanie się do zmian sił drużyn.

3.2 Dlaczego profesjonalne League of Legends?

Wybór profesjonalnych meczów *League of Legends* jako obszaru badawczego wynika nie tylko z popularności gry, lecz przede wszystkim z jej przydatności jako przypadku testowego dla modeli przedmeczowych. Dane łączą trzy elementy rzadko występujące jednocześnie: długą historię wyników, identyfikowalne składy zawodników oraz zewnętrzny benchmark w postaci kursów bukmacherskich. Dzięki temu można badać zarówno modele rankingowe, jak i jakość końcowych prawdopodobieństw względem rynku.

Z punktu widzenia pracy inżynierskiej jest to środowisko pośrednie między klasycznym sportem drużynowym a systemem cyfrowym. Podobnie jak w tradycyjnych ligach występują tu forma, siła zawodników, poziom przeciwnika i format rozgrywek. Jednocześnie gra podlega regularnym aktualizacjom, a składy mogą zmieniać się szybciej niż w wielu sportach tradycyjnych. Taka kombinacja uzasadnia użycie modeli aktualizowanych chronologicznie oraz ocenę ich stabilności w czasie.

Istotny jest także charakter istniejących badań. Część prac dotyczących *League of Legends* koncentruje się na predykcji w trakcie trwania gry, gdy znane są już statystyki meczowe, takie jak złoto, zabójstwa, obrażenia lub inne zmienne opisujące aktualny stan rozgrywki. Przykładowo Lin pokazał, że predykcja oparta na informacjach przedmeczowych była znacznie słabsza niż predykcja wykorzystująca statystyki z trwającej gry (L. Lin 2016). Podobnie praca Juniora i Campelo dotyczy predykcji w czasie rzeczywistym i oceny modeli na różnych etapach meczu, osiągając najwyższe wyniki w środkowych fazach rozgrywki (Junior i Campelo 2023). Inne prace wykorzystują informacje dostępne po wyborze postaci, na przykład doświadczenie zawodników na wybranych bohaterach (Do i in. 2021).

Na tym tle niniejsza praca przyjmuje węższe i trudniejsze założenie informacyjne: model ma przewidywać wynik profesjonalnego meczu przed jego rozpoczęciem, bez dostępu do statystyk z bieżącej gry ani do informacji powstających po starcie spotkania. Zamiast tego wykorzystuje wyłącznie historię wcześniejszych meczów, systemy rankingowe, miary niepewności oraz historyczne agregaty formy. Takie ujęcie odróżnia pracę od badań typu live prediction i lepiej odpowiada zadaniu porównania z kursem otwarcia rynku bukmacherskiego.

3.3 Źródła danych

W pracy zebrano dwa właściwe źródła danych. Pierwszym źródłem jest serwis GOL.GG (Games of League) (Games of League 2026), udostępniający dane sportowe dotyczące profesjonalnych meczów *League of Legends*. W dalszej części pracy stosowana jest wyłącznie skrócona nazwa GOL.GG. Dane te obejmują między innymi datę rozegrania spotkania, nazwy drużyn, wynik meczu, format serii oraz informacje dotyczące poszczególnych gier

i zawodników.

Drugim źródłem są historyczne kursy bukmacherskie pochodzące z serwisu OddsPortal (OddsPortal 2026). W pracy kursy nie są wykorzystywane do budowy strategii zakładów, lecz jako benchmark predykcyjny. Prawdopodobieństwa implikowane przez kursy bukmacherskie stanowią punkt odniesienia dla modeli opartych wyłącznie na danych sportowych.

Pozostałe zbiory wykorzystywane w eksperymentach mają charakter pośredni. Powstały w wyniku przetworzenia danych sportowych, na przykład przez wyznaczenie predykcji systemów rankingowych lub obliczenie historycznych cech kroczących. Nie stanowią one dodatkowych, zewnętrznych źródeł informacji. Rozróżnienie to jest istotne, ponieważ część badawcza pracy opiera się na dwóch źródłach pierwotnych: GOL.GG oraz OddsPortal.

Zakres danych można podzielić na dwa poziomy. Pełny zbiór GOL.GG służy do odtwarzania historii sportowej, generowania rankingów oraz obliczania cech historycznych. Główna ewaluacja wyników odbywa się jednak na wspólnej próbce meczów, dla których dostępne są zarówno dane sportowe, jak i kursy bukmacherskie. Takie ograniczenie zapewnia porównywalność modeli z rynkiem bukmacherskim.

Po przygotowaniu danych pełna historia sportowa obejmowała 40 656 meczów z lat 2013–2026 oraz 66 223 pojedyncze gry. Najliczniejszą grupę stanowiły mecze Bo1, ale w danych obecne były również serie Bo3 i Bo5. Zbiór kursów bukmacherskich obejmował 16 375 dopasowanych meczów z okresu od 6 kwietnia 2017 roku do 22 marca 2026 roku. Z punktu widzenia końcowej ewaluacji najważniejsza jest nie sama liczba rekordów, lecz fakt, że wspólna próbka pozwala porównać predykcje modelu sportowego i rynku na tych samych spotkaniach.

Tabela 3.1: Źródła danych i zbiory pośrednie wykorzystywane w pracy

Element	Typ	Rola w pracy
GOL.GG	źródło pierwotne	dane sportowe i historia meczów
OddsPortal	źródło pierwotne	historyczne kursy bukmacherskie
Predykcje rankingowe	zbiór pośredni	cechy wejściowe metamodelu
Cechy kroczące	zbiór pośredni	historyczny kontekst formy

Tabela 3.2: Podstawowe wielkości analizowanych zbiorów danych

Zakres	Liczba obserwacji	Okres	Rola w analizie
Mecze sportowe GOL.GG	40 656	2013–2026	historia sportowa i rankingi
Pojedyncze gry GOL.GG	66 223	2013–2026	statystyki gry i kontekst
Mecze z kursami OddsPortal	16 375	2017–2026	benchmark rynkowy
Finalna próbka model–rynek	11 609	2021–2026	końcowe porównanie modeli

3.4 Zakres informacyjny danych sportowych

Dane sportowe z GOL.GG mają strukturę hierarchiczną. Najwyższym poziomem obserwacji jest mecz, czyli spotkanie dwóch drużyn rozstrzygane w formacie Bo1, Bo3 albo Bo5. Pojedynczy mecz może składać się z jednej lub kilku gier. Z tego powodu w pracy rozróżniono poziom meczu, na którym definiowany jest wynik predykcji, oraz poziom gry, na którym dostępna jest część statystyk opisujących przebieg rozgrywki.

Na poziomie meczu dostępne są przede wszystkim: data spotkania, nazwy i identyfikatory drużyn, nazwa turnieju, format serii, wynik końcowy oraz informacja, która drużyna wygrała. Te zmienne są wykorzystywane do uporządkowania obserwacji w czasie, zdefiniowania zmiennej objaśnianej oraz segmentacji wyników według formatu meczu i poziomu rozgrywek.

Na poziomie gry dostępne są informacje bardziej szczegółowe. Obejmują one między innymi składy zawodników, wynik pojedynczej gry oraz statystyki drużynowe i zawodnicze opisujące przebieg meczy. W tej grupie znajdują się zmienne takie jak liczba zabójstw, zadane obrażenia, udział w obrażeniach, tempo gry oraz przewaga w złocie w określonym momencie gry. W pracy nie wykorzystano ich jako informacji z aktualnego meczu. Zamiast tego posłużyły do budowy historycznych agregatów, obliczanych wyłącznie na podstawie wcześniejszych występów.

Tabela 3.3: Główne grupy zmiennych sportowych wykorzystywanych w pracy

Grupa zmiennych	Przykładowe informacje	Rola w pracy
Identyfikacja meczu	data, turniej, drużyny, identyfikator meczu	porządkowanie danych, dopasowanie do kursów, walidacja chronologiczna
Wynik meczu	zwycięzca, wynik serii, format Bo1/Bo3/Bo5	definicja zmiennej objaśnianej i segmentacja wyników
Skład drużyn	zawodnicy Team 1 i Team 2, role graczy	budowa rankingów zawodniczych i porównanie z rankingami drużynowymi
Statystyki gry	zabójstwa, obrażenia, tempo gry, GD@15	źródło historycznych cech kroczących opisujących formę i styl drużyny
Poziom rozgrywek	liga, turniej, segment Tier 1 lub Regional/ERL	analiza stabilności wyników w różnych segmentach sceny

Najważniejsze jest rozróżnienie pomiędzy zmiennymi dostępnymi przed meczem a zmiennymi powstającymi w trakcie gry. Wynik aktualnej gry, aktualne zabójstwa lub aktualna przewaga w złocie nie mogą być użyte do predykcji przedmeczowej. Mogą natomiast zostać przekształcone w cechy historyczne, jeżeli są obliczane wyłącznie na podstawie wcześniejszych meczów tej samej drużyny.

3.5 Zakres informacyjny danych bukmacherskich

Dane z OddsPortal opisują rynek kursów dla meczów profesjonalnych. Dla każdego dopasowanego spotkania dostępne są kursy na zwycięstwo obu stron meczu. W pracy szczególne znaczenie mają dwie wersje kursów: kurs otwarcia oraz kurs zamknięcia.

Kurs otwarcia reprezentuje wcześniejszą wycenę rynku i jest najbliższy momentowi, w którym model przedmeczowy mógłby zostać użyty. Kurs zamknięcia jest ceną późniejszą, zwykle bliższą rozpoczęciu meczu. Może więc zawierać dodatkowe informacje, korekty rynku oraz reakcję na zmiany dostępnej wiedzy. Z tego powodu w pracy kurs zamknięcia traktowany jest jako benchmark diagnostyczny, a nie jako informacja dostępna w tym samym momencie co pierwotna predykcja modelu.

Tabela 3.4: Główne grupy zmiennych rynkowych wykorzystywanych w pracy

Grupa zmiennych	Przykładowe informacje	Rola w pracy
Identyfikacja spotkań	data, nazwy drużyn, turniej, strony meczu	dopasowanie kursów do danych GOL.GG
Kursy otwarcia	średni kurs rynkowy i kursy bukmacherów przed korektami rynku	główny benchmark przedmeczowy
Kursy zamknięcia	kursy bliższe rozpoczęciu meczu	silniejszy benchmark diagnostyczny
Bukmacherzy	Betclic, Betfan, eFortuna, LV BET, STS, Superbet	analiza pokrycia i marży poszczególnych źródeł kursów
Prawdopodobieństwa bez marży	znormalizowane prawdopodobieństwa implikowane z kursów	porównanie z prawdopodobieństwami modeli

3.6 Definicja problemu predykcyjnego

Problem badawczy został sformułowany jako binarna predykcja zwycięzcy meczu. Dla każdego spotkania model przewiduje prawdopodobieństwo zwycięstwa pierwszej drużyny w uporządkowanej parze meczowej. Zmienną objaśnianą oznaczono jako:

$$y = \begin{cases} 1, & \text{jeżeli pierwsza drużyna wygrała mecz,} \\ 0, & \text{jeżeli pierwsza drużyna przegrała mecz.} \end{cases} \quad (3.1)$$

Modele generują wartość $\hat{p}$, interpretowaną jako szacowane prawdopodobieństwo zdarzenia $y = 1$. W pracy nie ograniczono się do klasyfikacji zwycięzcy przy progu 0,5. Istotniejsza jest jakość prawdopodobieństwa, ponieważ dobrze skalibrowany model powinien nie tylko wskazywać bardziej prawdopodobną drużynę, lecz także realistycznie oceniać poziom niepewności.

3.7 Kursy bukmacherskie jako benchmark probabilistyczny

Kursy bukmacherskie zapisane w formacie dziesiętnym można przekształcić na prawdopodobieństwa implikowane. Dla rynku dwuwynikowego, w którym dostępny jest kurs na zwycięstwo pierwszej i drugiej drużyny, surowe prawdopodobieństwa wynikające z kursów mają postać:

$$q_1 = \frac{1}{o_1}, \quad q_2 = \frac{1}{o_2}, \quad (3.2)$$

gdzie o_1 i o_2 oznaczają kursy dziesiętne na odpowiednio pierwszą i drugą drużynę. Ponieważ kursy zawierają marżę bukmachera, suma $q_1 + q_2$ zwykle przekracza jeden. W celu uzyskania prawdopodobieństwa porównywalnego z modelem zastosowano normalizację bez marży:

$$p_1 = \frac{q_1}{q_1 + q_2} = \frac{1/o_1}{1/o_1 + 1/o_2}. \quad (3.3)$$

W pracy rozróżniono dwa typy kursów. Kursy otwarcia, oznaczane jako *Market Open*, traktowane są jako operacyjny punkt odniesienia, ponieważ reprezentują informację dostępną wcześniej. Kursy zamknięcia, oznaczane jako *Market Close*, mają charakter diagnostyczny. Zawierają późniejszą informację rynkową i dlatego nie powinny być interpretowane jako cena dostępna w momencie pierwszej predykcji.

W zbiorze kursów dostępne były średnie kursy rynkowe oraz kursy wybranych bukmacherów. W analizie uwzględniono przede wszystkim Betclic, Betfan, eFortuna, LV BET, STS oraz Superbet. W danych technicznych występowały również kolumny dla Fuksiarza, jednak w analizowanej wersji zbioru nie miały one użytecznego pokrycia i nie zostały wykorzystane w porównaniach jakości rynku. Mediana średniego kursu otwarcia wynosiła 1,78 dla pierwszej strony meczu oraz 1,93 dla drugiej strony. Maksymalne obserwowane wartości średnich kursów otwarcia wynosiły odpowiednio 16,50 oraz 19,00, co pokazuje obecność wyraźnych faworytów i underdogów.

Tabela 3.5: Zakres średnich kursów rynkowych w zbiorze OddsPortal

Zmienna	Liczba obserwacji	Minimum	Mediana	Maksimum
Kurs otwarcia – strona 1	16 316	1,00	1,78	16,50
Kurs otwarcia – strona 2	16 316	1,00	1,93	19,00
Kurs zamknięcia – strona 1	16 316	1,00	1,79	16,50
Kurs zamknięcia – strona 2	16 316	1,01	1,93	16,06

3.8 Przygotowanie i dopasowanie danych

Istotnym etapem przygotowania danych było dopasowanie meczów sportowych z GOL.GG do meczów posiadających kursy bukmacherskie z OddsPortal. Dopasowanie to wymagało uwzględnienia daty spotkania, nazw drużyn, stron meczu oraz wyniku końcowego. Celem tego etapu było utworzenie wspólnej próbki obserwacji, w której dla tego samego meczu dostępne są zarówno informacje sportowe, jak i benchmark rynkowy.

Na podstawie danych sportowych wyznaczono następnie cechy używane w modelowaniu. Systemy rankingowe były aktualizowane chronologicznie po każdym meczu, a przed kolejnym spotkaniem generowały predykcję siły drużyn. Dodatkowo obliczono cechy historyczne opisujące ostatnią formę zespołów. Wszystkie te zmienne powstały wyłącznie z informacji dostępnych przed analizowanym meczem.

Sz szczególnie ważne było również zachowanie poprawnej orientacji stron meczu. W części rekordów kolejność drużyn w historycznym zbiorze kursów różniła się od kolejności drużyn w danych sportowych. Z tego powodu prawdopodobieństwa rynkowe zostały wyrównane do tej samej strony, dla której modele generowały predykcję. Rekordy, dla których nie można było jednoznacznie ustalić orientacji, zostały wyłączone z finalnej wspólnej próbki ewaluacyjnej.

3.9 Braki danych i ograniczenia próby

Zgromadzone dane są wystarczające do budowy modeli rankingowych i probabilistycznych, ale nie opisują pełnego kontekstu sportowego meczu. W szczególności w pracy nie wykorzystano informacji o wyborze postaci, fazie draftu, planowanych strategiach, stanie zdrowia zawodników, zmianach treningowych ani wewnętrznej sytuacji organizacji. Część z tych informacji może być znana uczestnikom rynku lub analitykom drużyn, ale nie jest dostępna w uporządkowanej, historycznej postaci dla całej analizowanej próby.

Drugim ograniczeniem jest pokrycie danych bukmacherskich. Nie wszystkie mecze z pełnej historii GOL.GG posiadają odpowiadające im kursy w OddsPortal. W konsekwencji finalna próba ewaluacyjna jest mniejsza od pełnej historii sportowej i obejmuje przede wszystkim mecze, dla których rynek bukmacherski faktycznie udostępniał ceny. Oznacza to, że końcowe porównanie z rynkiem dotyczy ważniejszej i bardziej obserwowalnej części profesjonalnej sceny, ale nie powinno być automatycznie uogólniane na wszystkie mecze dostępne w GOL.GG.

Trzecim ograniczeniem jest nierównomierne pokrycie bukmacherów. Część firm ma dużą liczbę obserwacji, natomiast inne występują rzadziej lub nie mają użytecznego pokrycia w analizowanej wersji danych. Z tego powodu w głównym benchmarku wykorzystano średnie prawdopodobieństwo rynkowe po normalizacji kursów, a nie predykcję pojedynczego bukmachera.

Ostatnim ograniczeniem jest interpretacja kursów zamknięcia. Market Close jest silnym benchmarkiem diagnostycznym, ponieważ zawiera późniejsze informacje i reakcję rynku. Nie jest jednak równoważny kursowi dostępnemu w momencie pierwotnej predykcji przedmeczowej. W pracy rozdzielono więc Market Open jako wcześniejszy punkt odniesienia oraz Market Close jako benchmark ex post.

3.10 Zasady unikania przecieku informacji

Wszystkie modele oceniane w pracy wymagają zachowania porządku czasowego. System rankingowy przed danym meczem może korzystać wyłącznie z wyników rozegranych wcześniej spotkań. Po wygenerowaniu predykcji wynik meczu jest używany do aktualizacji ratingów, ale tylko dla kolejnych obserwacji. Analogiczna zasada dotyczy cech historycznych, takich jak średnia forma lub statystyki kroczące.

Takie podejście odpowiada realistycznemu scenariuszowi predykcyjnemu. Model nie zna przyszłych wyników, przyszłych składów ani późniejszych zmian kursów. W szczególności cechy opisujące przebieg aktualnej gry, takie jak przewaga w złocie w piętnastej minucie bieżącej mapy, nie mogą być używane bezpośrednio do predykcji przedmeczowej. Mogą natomiast zostać wykorzystane w formie historycznych średnich kroczących, obliczonych na podstawie wcześniejszych występów drużyny.

3.11 Uzasadnienie wyboru głównej próbki ewaluacyjnej

Chociaż pełny zbiór GOL.GG jest większy niż zbiór meczów z kursami, główne wyniki pracy raportowane są na wspólnej próbce danych sportowych i rynkowych. Decyzja ta wynika z celu pracy, którym jest porównanie modelu sportowego z rynkiem bukmacherskim. Tylko mecze posiadające kursy pozwalają zestawić predykcje modelu, rankingów oraz benchmarku rynkowego na tych samych obserwacjach.

Pełny zbiór GOL.GG pozostaje jednak istotny, ponieważ dostarcza historycznej informacji potrzebnej do budowania ratingów i cech kroczących. Ostateczna metodologia rozdziela zatem dwa zastosowania danych: szeroka historia sportowa służy do konstruowania sygnałów predykcyjnych, natomiast wspólna próbka danych sportowych i rynkowych służy do głównej ewaluacji i weryfikacji hipotez.

Rozdział 4

Eksploracyjna analiza danych

4.1 Cel analizy eksploracyjnej

Eksploracyjna analiza danych służy rozpoznaniu struktury próby przed budową modeli. W pracy ma trzy funkcje: sprawdza zróżnicowanie danych w czasie, formacie serii i poziomie rozgrywek, kontroluje balans zmiennej objaśnianej oraz wstępnie ocenia siłę rynku bukmacherskiego jako benchmarku.

EDA nie zastępuje eksperymentów modelowych. Uzasadnia natomiast późniejsze decyzje: walidację chronologiczną, segmentację Bo1/Bo3/Bo5, kontrolę poziomu rozgrywek oraz rozdzielenie kursów otwarcia i zamknięcia.

4.2 Zakres czasowy i charakter próbki

Dane sportowe obejmują wiele sezonów profesjonalnych rozgrywek *League of Legends*. Jest to korzystne dla systemów rankingowych, ale oznacza także niejednorodność: w czasie zmieniały się składy, formaty rozgrywek, liczba turniejów oraz sama gra.


Z tego powodu w dalszej części pracy nie stosuje się losowego podziału obserwacji na zbiór treningowy i testowy. Taki podział mógłby prowadzić do sytuacji, w której model uczy się na meczach rozegranych po spotkaniach znajdujących się w zbiorze testowym. Zamiast tego zastosowano podejście chronologiczne, w którym predykcja dla danego meczu może korzystać jedynie z informacji dostępnych przed jego rozegranie.

Wspólna próbka sportowo-rynkowa jest mniejsza od pełnej historii GOL.GG, ale tylko ona pozwala bezpośrednio porównać model z rynkiem. Dlatego w EDA dodatkowo sprawdzono, czy mecze z kursami nie są nadmiernie skupione na jednym poziomie rozgrywek.




Rysunek 4.1: Liczba meczów sportowych w kolejnych latach w danych GOL.GG.

Rysunek 4.1 pokazuje, że liczba obserwacji meczowych zmienia się w czasie. Sam wykres meczów nie opisuje jednak w pełni aktywności sceny esportowej, ponieważ pojedynczy mecz może składać się z jednej, trzech lub pięciu gier. Z tego powodu obok liczby meczów należy analizować także liczbę pojedynczych gier.



Rysunek 4.2: Liczba pojedynczych gier w kolejnych latach w danych GOL.GG.

Zestawienie rysunki 4.1 i 4.2 prowadzi do ważnej obserwacji. Po 2022 roku liczba rekordów meczowych maleje, ale liczba rozegranych gier pozostaje relatywnie wysoka. W aktualnej próbkę rok 2025 zawiera mniej meczów niż lata 2021–2024, natomiast liczba pojedynczych gier jest nadal zbliżona do najwyższych wartości w całym szeregu czasowym. Nie oznacza to więc prostego spadku aktywności sceny, lecz zmianę struktury kalendarza i większy udział serii wielomapowych.



Rysunek 4.3: Liczba meczów w kolejnych latach z podziałem według formatu serii.


Wykres skumulowany na rysunku 4.3 pokazuje, jak zmieniał się udział formatów Bo1, Bo3 i Bo5. Jest to istotne, ponieważ etykieta predykcyjna i kursy bukmacherskie są zdefiniowane na poziomie meczu, natomiast część statystyk sportowych powstaje na poziomie pojedynczych gier. Większy udział Bo3 i Bo5 może więc utrzymywać wysoką liczbę rozegranych map mimo mniejszej liczby rekordów meczowych.

4.3 Zmienna objaśniana i balans klas

Zmienną objaśnianą jest zwycięstwo pierwszej drużyny w uporządkowanej parze meczowej. W idealnym przypadku, przy losowym przypisaniu stron, udział zwycięstw pierwszej drużyny byłby bliski 50%. W praktyce może występować niewielkie odchylenie od tej wartości, wynikające z konwencji zapisu meczów, kolejności drużyn w źródłach danych lub specyfiki dopasowania danych sportowych do kursów.

Balans klas ma znaczenie dla interpretacji metryk. Sama trafność klasyfikacji przy progu 0,5 nie jest wystarczającą miarą jakości, ponieważ model może osiągać pozornie dobre wyniki przez preferowanie częstszej klasy. Dlatego w dalszej części pracy podstawowymi miarami są AUC, LogLoss, Brier score oraz ECE. Metryki te oceniają nie tylko wskazanie zwycięzcy, lecz także jakość przypisanego prawdopodobieństwa.

Rozkład zwycięstw według strony / pozycji w payloadzie



Rysunek 4.4: Udział zwycięstw stron meczu w danych sportowych.


Wizualizacja na rysunku 4.4 pełni funkcję kontroli podstawowej struktury celu predykcyjnego. Jeżeli jedna ze stron byłaby dominująca wyłącznie z powodu sposobu zapisu danych, proste metryki klasyfikacyjne mogłyby być mylące. Z tego powodu w pracy nacisk położono na metryki probabilistyczne.

4.4 Formaty meczów

Profesjonalne mecze *League of Legends* mogą być rozgrywane w różnych formatach serii. Najczęściej spotykane są formaty Bo1, Bo3 oraz Bo5. Różnią się one nie tylko liczbą gier potrzebnych do rozstrzygnięcia meczu, lecz także poziomem losowości wyniku.

W formacie Bo1 pojedyncza gra decyduje o wyniku całego meczu. Taki format jest bardziej podatny na jednorazowe błędy, nietypowe strategie lub specyficzne przygotowanie do konkretnego przeciwnika. W formacie Bo3 drużyna musi wygrać dwie gry, co częściowo redukuje wpływ pojedynczego zdarzenia. Format Bo5 jest zwykle stosowany w fazach pucharowych i finałach, przez co obejmuje specyficzną grupę meczów o wysokiej stawce.

Segmentacja według formatu jest istotna, ponieważ model może działać z różną skutecznością w zależności od typu serii. W późniejszej ewaluacji najlepsze wyniki osiągnęte są w formacie Bo3, natomiast format Bo5 okazuje się trudniejszy do oceny. Wynika to prawdopodobnie z mniejszej liczby obserwacji oraz specyfiki meczów play-off, w których mierzą się silniejsze i bardziej wyrównane drużyny.




Rysunek 4.5: Rozkład formatów serii w danych sportowych.

Rozkład przedstawiony na rysunku 4.5 uzasadnia raportowanie wyników w segmentach Bo1, Bo3 i Bo5. Segmenty te różnią się liczebnością i charakterem sportowym, dlatego końcowa ocena modelu nie powinna ograniczać się wyłącznie do jednej zagregowanej metryki.

4.5 Poziom rozgrywek

Drugim wymiarem segmentacji jest poziom rozgrywek. Stabilność składów, dostępność informacji i efektywność rynku mogą różnić się między ligami najwyższego poziomu a rozgrywkami regionalnymi. Segmentacja służy tu kontroli struktury próby, a nie budowie osobnych modeli dla każdego poziomu.

Ponieważ GOL.GG nie zawiera jawnej zmiennej poziomu rozgrywek, zastosowano operacyjny podział na Tier 1 i Tier 2. Tier 1 obejmuje turnieje międzynarodowe najwyższego poziomu oraz główne ligi LCK, LPL, LEC i LCS, natomiast Tier 2 pozostałe rozgrywki regionalne, ligi akademickie i challengers. Jest to heurystyka oparta na nazwie turnieju, a nie oficjalna klasyfikacja Riot Games.



Rysunek 4.6: Udział meczów Tier 1 i Tier 2 w pełnej próbie sportowej od 2020 roku oraz we wspólnej próbie z kursami bukmacherskimi.

Tabela 4.1: Struktura poziomu rozgrywek w danych sportowych i w próbie bukmacherskiej

Próba	Segment	Liczba meczów	Udział [%]
GOL.GG 2020+	Tier 1 / major	6 159	20,3
GOL.GG 2020+	Tier 2 / regionalne	24 157	79,7
Próba z kursami	Tier 1 / major	4 448	38,3
Próba z kursami	Tier 2 / regionalne	7 161	61,7


Rysunek 4.6 i tabela 4.1 pokazują, że wspólna próba z kursami nie jest zdominowana wyłącznie przez niszowe rozgrywki. W porównaniu z pełną historią sportową od 2020 roku ma ona wyższy udział meczów Tier 1: około 38,3% wobec 20,3%. Jednocześnie nadal zawiera dużą część rozgrywek Tier 2, co oznacza, że końcowa ewaluacja obejmuje zarówno najbardziej rozpoznawalne ligi i turnieje, jak i segment regionalny. Taka struktura jest korzystna dla celu pracy: rynek bukmacherski dostarcza benchmark głównie tam, gdzie mecz jest wystarczająco istotny, aby zostać wyceniony, ale próba nie redukuje się wyłącznie do jednego wąskiego poziomu rozgrywek.

4.6 Rynek bukmacherski jako punkt odniesienia

Kursy bukmacherskie są silnym benchmarkiem, ponieważ agregują informacje o drużynach, składach, formie i reakcji rynku. W pracy rozróżniono kursy otwarcia, bliższe realistycznej predykcji przedmeczowej, oraz kursy zamknięcia, traktowane jako silniejszy benchmark diagnostyczny.

Na wspólnej próbce historycznej rynek otwarcia osiąga wyniki wyraźnie lepsze od losowego klasyfikatora, co potwierdza, że kursy zawierają istotną informację predykcyjną.

Rynek zamknięcia jest zwykle silniejszy od rynku otwarcia, co jest zgodne z intuicją: im bliżej meczu, tym więcej informacji może zostać uwzględnionych w cenie.




Rysunek 4.7: Porównanie jakości kursów otwarcia i zamknięcia jako benchmarku probabilistycznego.

Tabela 4.2: Orientacyjne wyniki benchmarku bukmacherskiego na wspólnej próbkce historycznej

Benchmark	AUC	LogLoss
Market Open	0,7325	0,6057
Market Close	0,7403	0,5992

Wyniki w tabeli 4.2 nie są jeszcze końcową oceną modelu. Pokazują natomiast, że rynek jest wymagającym punktem odniesienia, a kurs zamknięcia jest silniejszy od kursu otwarcia.

Jakość benchmarku bukmacherskiego nie musi być jednak taka sama dla każdego formatu serii. W formacie Bo1 pojedyncza gra decyduje o wyniku meczu, natomiast w Bo3 i Bo5 wynik całej serii zależy od kilku gier. Z tego powodu dodatkowo sprawdzono, jak LogLoss kursów otwarcia i zamknięcia zmienia się pomiędzy segmentami Bo1, Bo3 i Bo5.




Rysunek 4.8: Jakość predykcji bukmacherów według formatu serii na wspólnej próbie z kursami. Niższy LogLoss oznacza lepszą jakość probabilistyczną.

Tabela 4.3: Jakość benchmarku bukmacherskiego według formatu serii

Format	Benchmark	Mecze	AUC	LogLoss	ECE
Bo1	Market Open	7 229	0,7206	0,6150	0,0139
Bo1	Market Close	7 229	0,7312	0,6068	0,0114
Bo3	Market Open	3 117	0,7784	0,5665	0,0213
Bo3	Market Close	3 117	0,7840	0,5604	0,0153
Bo5	Market Open	1 263	0,6682	0,6398	0,0544
Bo5	Market Close	1 263	0,6742	0,6382	0,0486

Rysunek 4.8 i tabela 4.3 pokazują, że rynek najlepiej radził sobie w segmencie Bo3. Dla kursu zamknięcia LogLoss wyniósł tam około 0,5604, wobec 0,6068 dla Bo1 i 0,6382 dla Bo5. Słabszy wynik Bo5 należy interpretować ostrożnie: segment jest mniejszy i obejmuje głównie mecze play-off oraz spotkania silnych drużyn. Analiza uzasadnia uwzględnienie formatu serii w cechach modelu.

Oprócz jakości predykcyjnej ważna jest marża kursów. Dla rynku dwuwynikowego można ją przybliżyć jako nadwyżkę sumy odwrotności kursów ponad jeden. W analizowanej próbie średnia marża kursów otwarcia wynosiła około 8,17%, a średnia ważona liczbą meczów około 8,29%. Dlatego surowe kursy wymagały normalizacji, a w tabeli 4.4 zestawiono jednocześnie pokrycie, marżę, AUC i LogLoss.



Rysunek 4.9: Średnia marża kursów otwarcia według bukmachera.

Tabela 4.4: Pokrycie danych, marża i jakość predykcyjna kursów otwarcia według bukmachera

Bukmacher	Mecze z kursem otwarcia	Pokrycie [%]	Marża [%]	AUC	LogLoss
Betclik	4 153	25,36	7,39	0,7418	0,5980
Superbet	9 444	57,67	8,05	0,7255	0,6111
Betfan	11 404	69,64	8,10	0,7298	0,6077
LV BET	13 159	80,36	8,19	0,7323	0,6061
STS	13 695	83,63	8,48	0,7299	0,6079
eFortuna	13 902	84,90	8,78	0,7307	0,6069
Średnia rynkowa	16 308	99,59	8,29	0,7325	0,6057

Betclik miał najniższą marżę i najlepszy LogLoss wśród pojedynczych bukmacherów, ale obejmował tylko około jedną czwartą próby. Największe pokrycie miały eFortuna, STS i LV BET. Średnia rynkowa obejmuje prawie całą próbę, dlatego jest stabilniejszym benchmarkiem niż pojedynczy operator.

4.7 Historyczne statystyki gry jako źródło kontekstu

Dane GOL.GG zawierają także informacje opisujące przebieg poszczególnych gier, między innymi statystyki zawodników i drużyn. Część takich zmiennych, na przykład przewaga w złocie w piętnastej minucie aktualnej gry, jest silnie związana z końcowym wynikiem. Nie może być jednak użyta bezpośrednio w predykcji przedmeczowej, ponieważ w momencie predykcji aktualna gra jeszcze się nie odbyła.

Jedną z takich zmiennych jest $GD@15$, czyli *gold difference at 15 minutes*. Oznacza ona różnicę w łącznej liczbie złota zgromadzonego przez obie drużyny w 15. minucie gry. Dodatnia wartość $GD@15$ dla drużyny oznacza, że po pierwszych 15 minutach miała ona przewagę ekonomiczną nad przeciwnikiem, natomiast wartość ujemna oznacza stratę. W praktyce jest to syntetyczna miara jakości wczesnej fazy gry, ponieważ złoto odzwierciedla zabójstwa, farmę, kontrolę mapy i zdobyte cele.

W predykcji przedmeczowej nie można użyć $GD@15$ z aktualnej gry, ponieważ ta wartość jest znana dopiero po rozpoczęciu meczu. Można natomiast obliczyć historyczne $GD@15$ drużyny, czyli średnią przewagę lub stratę w złocie w 15. minucie w jej wcześniejszych grach. Taka zmienna opisuje, czy dana drużyna zwykle dobrze rozpoczynała swoje mecze i czy potrafiła budować przewagę ekonomiczną we wczesnej fazie gry.

Z tego powodu w pracy wykorzystano wyłącznie historyczne agregaty takich informacji. Przykładowo, zamiast używać przewagi w złocie z aktualnej gry, obliczono średnią przewagę w złocie z wcześniejszych występów drużyny. Następnie dla każdego meczu wyznaczono różnicę tych średnich wartości pomiędzy Team 1 i Team 2. Taka cecha opisuje wcześniejszy styl oraz formę zespołu przed meczem, a jednocześnie nie narusza zasady chronologicznego dostępu do informacji.

Formalnie, dla meczu rozgrywanego w chwili t , historyczna cecha Team 1 może być zapisana jako średnia z wcześniejszych gier tej drużyny:

$$\overline{GD@15}_{Team1,t} = \frac{1}{K} \sum_{k=1}^K GD@15_{Team1,t-k}, \quad (4.1)$$

gdzie K oznacza liczbę wcześniejszych gier uwzględnionych w oknie historycznym. W analizie eksploracyjnej i późniejszych modelach najważniejsza jest różnica pomiędzy analogicznymi wartościami dla obu drużyn:

$$\Delta GD@15_t = \overline{GD@15}_{Team1,t} - \overline{GD@15}_{Team2,t}. \quad (4.2)$$

Dodatnia wartość $\Delta GD@15_t$ oznacza, że Team 1 miał historycznie lepszą wczesną fazę gry niż Team 2, natomiast wartość ujemna oznacza przewagę Team 2 w tym aspekcie.


Ta obserwacja uzasadnia późniejsze wprowadzenie metamodelu z kontekstem historycznym. Same ratingi opisują ogólną siłę zawodników i drużyn, ale cechy kroczące mogą dostarczyć dodatkowej informacji o aktualnej formie, dynamice gry oraz niedawnych wynikach.

Zależność pomiędzy historyczną przewagą $GD@15$ a wynikiem meczu można ocenić bez używania informacji z aktualnej gry. Dla czytelności analizę ograniczono do części próby z lat 2024–2026, dla której dostępne były kursy bukmacherskie. Pominięto również mecze, w których różnica historycznego $GD@15$ była równa zero, ponieważ nie wskazywały one przewagi żadnej ze stron. W tak zdefiniowanej próbie Team 1 wygrywał około

65,2% meczów, gdy jego historyczne GD@15 było wyższe od rywala, oraz około 42,5% meczów, gdy było niższe. Oznacza to, że historyczny profil early game był powiązany z późniejszym wynikiem meczu.

Siłę tej zależności sprawdzono również prostą diagnostyką jednowymiarową. Korelacja Pearsona pomiędzy różnicą historycznego GD@15 a wynikiem meczu wyniosła około 0,252, a korelacja rang Spearmana około 0,259. Jednowymiarowa regresja logistyczna oparta wyłącznie na tej zmiennej uzyskała AUC równe 0,650 i LogLoss równy 0,656. Wynik ten jest zbyt słaby, aby traktować historyczne GD@15 jako samodzielny model predykcyjny, ale wystarczająco wyraźny, aby uzasadnić pozostawienie tej zmiennej jako składnika szerszego kontekstu historycznego.

Tę samą zmienną można następnie przedstawić w sposób zagregowany, dzieląc mecze na przedziały różnicy historycznego GD@15 i obliczając rzeczywisty udział zwycięstw Team 1 w każdym przedziale. Taka wizualizacja bezpośrednio pokazuje, czy historyczna przewaga wczesnej fazy gry była powiązana z późniejszym wynikiem meczu.



Rysunek 4.10: Relacja pomiędzy różnicą średniego historycznego GD@15 a rzeczywistym win rate Team 1.

Rysunek 4.10 pokazuje tę zależność w formie wykresu punktowego po przedziałach GD@15. Każdy punkt oznacza przedział różnicy historycznego GD@15, jego położenie na osi pionowej odpowiada rzeczywistemu win rate Team 1, a wielkość punktu informuje o liczbie meczów w danym przedziale. Wraz ze wzrostem historycznej przewagi GD@15 rośnie rzeczywisty udział zwycięstw Team 1. Oznacza to, że historyczna siła drużyn w early game pozostaje użytecznym kandydatem do modelu kontekstowego, mimo że nie wykorzystuje informacji z aktualnego meczu.

4.8 Obserwacje nietypowe i konsekwencje dla modelowania

Analiza eksploracyjna ujawniła kilka cech próby istotnych dla interpretacji wyników. Po pierwsze, liczba meczów i liczba pojedynczych gier nie zawsze zmieniają się równolegle, ponieważ formaty Bo3 i Bo5 generują więcej map na jeden rekord meczowy. Po drugie, Bo5 jest mniejszym i specyficznym segmentem play-off, dlatego jego wyniki należy interpretować ostrożnie. Po trzecie, mecze z bardzo wysokimi kursami mogą silnie wpływać na LogLoss, co wzmacnia znaczenie metryk probabilistycznych. Po czwarte, Market Open i Market Close pełnią różne role: pierwszy jest wcześniejszym punktem odniesienia, drugi silniejszym benchmarkiem diagnostycznym.

4.9 Wnioski z analizy eksploracyjnej

Z EDA wynikają trzy decyzje metodologiczne. Po pierwsze, predykcja musi być oceniana chronologicznie. Po drugie, format meczu i poziom rozgrywek powinny być analizowane jako segmenty próby. Po trzecie, pełna historia sportowa służy do budowy ratingów i cech historycznych, natomiast wspólna próbka z kursami służy do końcowego porównania z rynkiem.

Rozdział 5

Metodyka oceny modeli

5.1 Cel rozdziału

Celem tego rozdziału jest określenie zasad, według których oceniane są systemy rankingowe, metamodel oraz benchmark bukmacherski. Jest to istotne, ponieważ badany problem nie polega wyłącznie na wskazaniu zwycięzcy meczu, lecz na oszacowaniu prawdopodobieństwa zwycięstwa jednej ze stron. Z tego względu metryki powinny oceniać jakość predykcji probabilistycznej, a nie tylko decyzję klasyfikacyjną po przyjęciu arbitralnego progu.

W pracy przyjęto, że każdy model zwraca wartość $\hat{p}_i \in (0, 1)$, interpretowaną jako prawdopodobieństwo zwycięstwa pierwszej strony meczu w obserwacji i . Rzeczywisty wynik oznaczono jako $y_i \in \{0, 1\}$, gdzie 1 oznacza zwycięstwo pierwszej strony, a 0 zwycięstwo drugiej strony.

5.2 Wspólna próba ewaluacyjna

Główna ewaluacja modeli w pracy jest prowadzona na wspólnej próbie meczów, dla których dostępne są zarówno dane sportowe z GOL.GG, jak i historyczne kursy bukmacherskie pochodzące z OddsPortal. Takie ograniczenie próby pozwala porównywać modele sportowe z benchmarkiem rynkowym w tych samych warunkach. Dzięki temu różnice w metrykach nie wynikają z odmiennego zakresu danych, lecz z jakości analizowanych predykcji.

Pełniejsza historia sportowa może być używana do budowy rankingów i historycznych cech kontekstowych, ponieważ w realistycznym scenariuszu predykcyjnym wcześniejsze wyniki zespołów i zawodników są znane przed meczem. Końcowe porównanie wyników odbywa się jednak na próbie wspólnej z rynkiem bukmacherskim. Jest to szczególnie ważne dla hipotezy dotyczącej konkurencyjności modelu względem kursów otwarcia i zamknięcia.

5.3 Zasada chronologicznej walidacji

Wszystkie modele oceniane w pracy muszą respektować kolejność czasową obserwacji. Oznacza to, że predykcja dla danego meczu może wykorzystywać wyłącznie informacje dostępne przed jego rozpoczęciem. Po zakończeniu meczu jego wynik może zostać użyty do aktualizacji rankingów lub cech historycznych, ale wyłącznie dla kolejnych obserwacji.

Takie podejście ogranicza ryzyko przecieku informacji. W szczególności niedopuszczalne byłoby używanie statystyk z aktualnie rozgrywanej gry, takich jak przewaga w złocie w piętnastej minucie, do predykcji wyniku przedmeczowego. Zmiennymi dopuszczalnymi są natomiast agregaty historyczne, obliczane na podstawie wcześniejszych meczów.

5.4 Bootstrap blokowy dla porównania modeli

Oprócz punktowych wartości metryk w pracy wykorzystano bootstrap blokowy do oceny stabilności różnic pomiędzy modelami. Jednostką losowania był miesiąc, ponieważ mecze z tego samego okresu mogą dotyczyć podobnych wersji gry, turniejów, składów i warunków rynkowych. Zwykły bootstrap losujący pojedyncze mecze mógłby zatem zaniżać niepewność przez ignorowanie zależności czasowych.

Dla każdego meczu liczono różnicę strat LogLoss pomiędzy modelem referencyjnym a modelem porównywanym, a następnie losowano miesięczne bloki z powtórzeniami i obliczano średnią różnicę w każdej próbie bootstrapowej. W ten sposób wyznaczano empiryczny przedział ufności dla różnicy jakości modeli. Znak różnicy definiowano osobno w każdym eksperymencie, tak aby interpretacja tabeli była jednoznaczna.

Bootstrap blokowy nie zastępuje walidacji chronologicznej, lecz ją uzupełnia. Walk-forward pokazuje wynik modelu w kolejnych okresach historycznych, natomiast bootstrap sprawdza, czy obserwowana różnica LogLoss jest stabilna względem zmian w składzie miesięcy ewaluacyjnych. Dlatego wybór finalnego modelu nie opiera się wyłącznie na pojedynczej wartości LogLoss, ale także na przedziałach ufności różnic względem wariantów alternatywnych i benchmarków.

Procedurę walk-forward stosowaną w eksperymentach można zapisać jako następującą sekwencję kroków:

1. Uporządkuj mecze chronologicznie według daty rozegrania.
2. Wybierz początkowy zbiór historyczny, który jest dostępny przed pierwszym okresem testowym.
3. Wytrenuj model wyłącznie na danych historycznych dostępnych w danym momencie.

4. Wygeneruj predykcje dla kolejnych N meczów, bez używania ich wyników ani statystyk pomeczowych.
5. Zapisz predykcje, rzeczywiste wyniki oraz wartości strat, np. LogLoss, do późniejszej analizy.
6. Po zakończeniu tych N meczów dopisz je do historii i zaktualizuj rankingi oraz cechy kroczące.
7. Powtarzaj kroki 3–6 aż do końca okresu ewaluacyjnego.
8. Po zebraniu wszystkich predykcji out-of-time pogrupuj błędy według miesięcy.
9. Losuj miesięczne bloki z powtórzeniami, aby uzyskać bootstrapowy rozkład różnic LogLoss.
10. Wyznacz przedział ufności dla Δ LogLoss i wykorzystaj go do oceny stabilności przewagi jednego modelu nad drugim.

Taki zapis lepiej oddaje praktyczną implementację eksperymentu: model nie otrzymuje jednego losowego podziału danych, lecz przechodzi po kolejnych fragmentach historii. Każda predykcja jest więc predykcją out-of-time, a bootstrap blokowy jest wykonywany dopiero po zakończeniu całej procedury walk-forward.

5.5 Metryki oceny

5.5.1 LogLoss

Podstawową metryką wyboru modelu jest LogLoss, czyli logarytmiczna strata dla klasyfikacji binarnej. Dla zbioru N obserwacji definiuje się ją następująco:

$$\text{LogLoss} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)]. \quad (5.1)$$

Metryka ta silnie karze predykcje pewne, ale błędne. Jeżeli model przypisuje bardzo wysokie prawdopodobieństwo zdarzeniu, które nie następuje, strata jest duża. Jest to pożądane w tej pracy, ponieważ model ma zwracać wiarygodne prawdopodobieństwa, a nie tylko klasyfikować mecze jako zwycięstwo lub porażkę. LogLoss należy do właściwych reguł punktacji, czyli zachęca model do raportowania prawdopodobieństw zgodnych z rzeczywistym przekonaniem predykcyjnym (Gneiting i Raftery 2007).

5.5.2 AUC

AUC mierzy zdolność modelu do rozróżniania zwycięskich i przegranych obserwacji. Intuicyjnie można ją interpretować jako prawdopodobieństwo, że losowo wybrany wygrany przypadek otrzyma wyższy wynik modelu niż losowo wybrany przegrany. Wartość 0,5 odpowiada klasyfikatorowi losowemu, a wartość 1 oznacza idealne uporządkowanie przypadków.

AUC jest użyteczna do oceny siły sygnału sportowego, ponieważ pokazuje, czy model poprawnie porządkuje mecze według szans zwycięstwa. Nie jest jednak wystarczającą metryką wyboru modelu probabilistycznego. Model może mieć wysokie AUC, ale jednocześnie generować źle skalibrowane prawdopodobieństwa.

5.5.3 Brier Score

Brier Score mierzy średni kwadratowy błąd predykcji probabilistycznej:

$$\text{Brier} = \frac{1}{N} \sum_{i=1}^N (\hat{p}_i - y_i)^2. \quad (5.2)$$

Niższa wartość oznacza lepszą jakość predykcji. W porównaniu z LogLoss metryka ta jest mniej surowa wobec bardzo pewnych błędów, ale jest łatwiejsza interpretacyjnie, ponieważ bezpośrednio mierzy odległość przewidywanego prawdopodobieństwa od rzeczywistego wyniku.

5.5.4 ECE

ECE, czyli expected calibration error, mierzy kalibrację prawdopodobieństw. Predykcje dzieli się na przedziały prawdopodobieństwa, a następnie porównuje średnie przewidywane prawdopodobieństwo z empirycznym odsetkiem zwycięstw w każdym przedziale. Ogólna postać metryki jest następująca:

$$\text{ECE} = \sum_{b=1}^B \frac{|S_b|}{N} |\text{acc}(S_b) - \text{conf}(S_b)|, \quad (5.3)$$

gdzie S_b oznacza zbiór obserwacji w przedziale b , $\text{acc}(S_b)$ empiryczny odsetek zwycięstw, a $\text{conf}(S_b)$ średnie przewidywane prawdopodobieństwo. Niska wartość ECE oznacza, że predykcje modelu są dobrze skalibrowane. Przykładowo, wśród meczów ocenionych przez model na około 70% rzeczywisty odsetek zwycięstw powinien być zbliżony do 70%.

5.5.5 Accuracy

Accuracy, czyli odsetek poprawnych klasyfikacji, jest w tej pracy metryką wyłącznie pomocniczą. Aby ją obliczyć, należy przyjąć próg decyzyjny, najczęściej 0,5. Taki próg

jest jednak arbitralny i nie wykorzystuje pełnej informacji zawartej w predykcji probabilistycznej. Dwa modele mogą mieć podobną accuracy, ale bardzo różną jakość prawdopodobieństw. Z tego powodu accuracy nie stanowi głównego kryterium wyboru modelu.

5.6 Hierarchia wyboru modelu

W pracy przyjęto hierarchię metryk dopasowaną do celu badania. Ponieważ model ma generować prawdopodobieństwa porównywalne z prawdopodobieństwami implikowanymi przez kursy bukmacherskie, najważniejsza jest jakość probabilistyczna. Pojedyncze wartości LogLoss, ECE, Brier Score i AUC traktowano jednak przede wszystkim jako informację diagnostyczną, wskazującą najbardziej obiecujące warianty modelu.

Stabilność wyboru potwierdzano dopiero miesięcznym bootstrappem blokowym różnic LogLoss. Jeżeli lepszy wynik punktowy nie był potwierdzony przedziałem ufności nie obejmującym zera, traktowano go jako sugestię, a nie jako stabilną poprawę. Hierarchia metryk określa więc, które własności modelu są najważniejsze, natomiast bootstrap blokowy sprawdza, czy obserwowana przewaga jest odporna na zmiany w składzie miesięcy ewaluacyjnych.

Tabela 5.1: Hierarchia metryk wykorzystywanych przy wyborze modelu

Priorytet	Metryka	Rola w pracy
1	LogLoss	Główna metryka kierunkowa; wskazuje kandydatów do wyboru, a stabilność różnic jest następnie sprawdzana bootstrappem blokowym.
2	ECE	Kryterium pomocnicze przy zbliżonym LogLoss; ocenia kalibrację prawdopodobieństw.
3	Brier Score	Dodatkowa miara błędu probabilistycznego, łatwiejsza interpretacyjnie niż LogLoss.
4	AUC	Ocena zdolności rozróżniania silniejszej strony meczu; nie decyduje samodzielnie o wyborze modelu.
5	Accuracy	Metryka pomocnicza, raportowana wyłącznie informacyjnie.

Jeżeli dwa modele uzyskują bardzo podobny LogLoss, preferowany jest model lepiej skalibrowany, czyli o niższym ECE, o ile nie pogarsza to stabilności głównej metryki. Je-

żeli różnice w LogLoss i ECE są niewielkie, pomocniczo analizowany jest Brier Score oraz AUC. Taka kolejność jest spójna z celem pracy: ważniejsze jest poprawne oszacowanie prawdopodobieństwa niż samo wskazanie bardziej prawdopodobnego zwycięzcy. Ostateczna interpretacja nie opiera się jednak na samym rankingu punktowych metryk, lecz na połączeniu: wartości LogLoss, kierunku różnicy względem alternatywy oraz przedziału ufności z bootstrapu blokowego.

5.7 Konsekwencje dla interpretacji wyników

Przyjęta hierarchia metryk wpływa na sposób interpretacji dalszych rozdziałów. Model o najwyższym AUC nie musi być modelem preferowanym, jeżeli jego LogLoss lub kalibracja są gorsze. Analogicznie, wysoka accuracy nie jest wystarczającym argumentem za wyborem modelu, ponieważ w problemie probabilistycznym istotne jest, czy wartości 0,60, 0,70 lub 0,80 odpowiadają rzeczywistej częstości zwycięstw.

Z tego powodu w końcowym porównaniu z benchmarkiem bukmacherskim szczególne znaczenie mają LogLoss, Brier Score i ECE. AUC pełni rolę uzupełniającą: pokazuje, czy model potrafi skutecznie porządkować mecze od mniej do bardziej prawdopodobnych zwycięstw pierwszej strony. Dzięki temu możliwe jest oddzielenie dwóch aspektów jakości modelu: siły rozróżniania oraz jakości kalibracji prawdopodobieństw.

Rozdział 6

Systemy rankingowe jako modele bazowe

6.1 Rola systemów rankingowych w predykcji

Systemy rankingowe stanowią pierwszy poziom modelowania siły sportowej. Ich zadaniem jest przekształcenie historii wyników w liczbową ocenę aktualnej siły drużyny lub zawodnika. W kontekście predykcji przedmeczowej ranking jest użyteczny, ponieważ może zostać obliczony wyłącznie na podstawie informacji dostępnych przed danym meczem. Po zakończeniu meczu ranking jest aktualizowany i może wpływać dopiero na kolejne predykcje.

W pracy systemy rankingowe pełnią dwie funkcje. Po pierwsze, są samodzielnymi modelami bazowymi, które można porównać z benchmarkiem bukmacherskim. Po drugie, generują cechy wejściowe dla metamodelu uczenia maszynowego. Metamodel nie zastępuje więc rankingów, lecz wykorzystuje je jako syntetyczne reprezentacje siły stron meczu.

6.2 Ranking drużynowy i ranking zawodniczy

W klasycznym ujęciu ranking może być przypisany drużynie. Takie podejście jest naturalne w wielu sportach zespołowych, ponieważ nazwa klubu często jest stabilnym nośnikiem informacji o sile. W profesjonalnym League of Legends założenie to jest jednak ograniczone. Organizacje esportowe regularnie zmieniają składy, a pojedynczy zawodnicy przenoszą znaczną część informacji o jakości gry pomiędzy drużynami.

Z tego powodu w pracy porównano dwa poziomy modelowania:

- **ranking drużynowy**, w którym aktualizowana jest ocena organizacji lub drużyny jako całości,
- **ranking zawodniczy**, w którym aktualizowane są oceny graczy występujących w danym meczu, a siła zespołu jest wyznaczana na podstawie składu.

Hipoteza badawcza H1 zakłada, że podejście zawodnicze powinno być skuteczniejsze od drużynowego. Wynika to z faktu, że w LoL skład osobowy jest bardziej bezpośrednim opisem rzeczywistej siły zespołu niż sama nazwa organizacji.

6.3 Zastosowane rodziny rankingów

6.3.1 Elo

System Elo jest jednym z najprostszych i najbardziej znanych systemów oceny siły graczy (Elo 1978). Model zakłada, że oczekiwany wynik zależy od różnicy rankingów dwóch stron. Po meczu ranking zwycięzcy rośnie, a ranking przegranego maleje. Wielkość zmiany zależy od tego, jak bardzo wynik różnił się od oczekiwania.

Zaletą Elo jest prostota i łatwa interpretacja. Ograniczeniem jest natomiast brak jawnego modelowania niepewności. Zawodnik z dużą liczbą rozegranych meczów i zawodnik z bardzo krótką historią mogą mieć podobny rating, mimo że pewność oszacowania ich siły jest różna.

6.3.2 Glicko-2

Glicko-2 rozwija ideę rankingów Elo przez wprowadzenie dodatkowych parametrów opisujących niepewność oceny (Glickman 2012). Oprócz samego ratingu model uwzględnia rating deviation, czyli miarę niepewności oszacowania siły. Jest to szczególnie istotne w środowisku esportowym, gdzie część zawodników ma długą historię występów, a część pojawia się w danych tylko okresowo.

W praktyce oznacza to, że wynik przeciwko dobrze znanemu zawodnikowi może być interpretowany inaczej niż wynik przeciwko zawodnikowi o bardzo niepewnym poziomie. Ta własność jest korzystna w danych obejmujących wiele lat, regionów i poziomów rozgrywek.

6.3.3 TrueSkill i OpenSkill

TrueSkill modeluje umiejętność gracza jako rozkład prawdopodobieństwa, a nie pojedynczą wartość punktową (Herbrich, Minka i Graepel 2007). Podejście to zostało zaprojektowane z myślą o grach wieloosobowych i zespołowych. OpenSkill jest otwartą implementacją podobnej klasy systemów rankingowych. W pracy modele te są traktowane jako alternatywne sposoby reprezentacji siły zawodników i drużyn.

6.3.4 Modele porównawcze

Uzupełniając wykorzystano także modele z rodziny Plackett–Luce oraz Thurstone–Mosteller. Ich rola w pracy jest głównie porównawcza: pozwalają sprawdzić, czy przewaga konkretnego systemu rankingowego wynika z ogólnej idei rankingu, czy ze specyfiki wybranej metody aktualizacji.

6.4 Procedura obliczania predykcji rankingowych

Predykcje rankingowe były generowane chronologicznie. Dla każdego meczu najpierw odczytywano aktualne rankingi drużyn lub zawodników, następnie obliczano prawdopodobieństwo zwycięstwa pierwszej strony, a dopiero po tym aktualizowano rankingi na podstawie wyniku. Taka procedura jest zgodna z zasadą unikania przecieku informacji opisaną w poprzednim rozdziale.

W przypadku rankingów zawodniczych siła strony była wyznaczana na podstawie zawodników występujących w danym meczu. Dzięki temu transfer zawodnika wpływał na ocenę nowego zespołu, zamiast pozostawać wyłącznie w historii poprzedniej organizacji.

6.5 Dobór parametrów systemów rankingowych

Same definicje rodzin rankingowych nie przesądzają jeszcze o ich jakości predykcyjnej. Każdy system wymaga przyjęcia parametrów opisujących tempo aktualizacji, skalę różnic siły lub sposób traktowania niepewności. Z tego powodu przed wyborem rankingów do dalszych etapów wykonano oddzielny eksperyment doboru parametrów. Nie był on traktowany jako strojenie końcowego modelu uczenia maszynowego, lecz jako sprawdzenie, czy słabsze wyniki niektórych rodzin rankingowych nie wynikają wyłącznie z niekorzystnego ustawienia parametrów domyślnych.

Dobór przeprowadzono w sposób chronologiczny. Okres 2021–2023 wykorzystano jako część walidacyjną do wyboru konfiguracji, natomiast okres 2024+ jako okres testowy. Dla Elo sprawdzano przede wszystkim wartość współczynnika aktualizacji K , dla Glicko-2 początkowe odchylenie rankingów oraz tempo wzrostu niepewności, dla TrueSkill parametry β i τ , a dla rodzin Plackett–Luce i Thurstone–Mosteller parametry skali i dryfu. Dla OpenSkill testowano przede wszystkim początkową wartość niepewności σ .

Taka procedura pozwala uczciwie porównać rodziny rankingowe po ich podstawowym dostrojeniu. Jednocześnie zachowuje warunek przedmeczowy: w każdej predykcji ranking był liczony wyłącznie na podstawie wcześniejszych meczów.

Po wyborze najlepszych konfiguracji predykcje rankingowe zostały wygenerowane ponownie i to one stanowiły wejście do dalszych eksperymentów metamodelu. Dzięki temu wyniki w kolejnych rozdziałach są spójne z parametrami raportowanymi w tym rozdziale.

6.6 Wyniki po doborze parametrów


Najważniejsze porównanie rankingów w pracy dotyczy meczów, które można później zestawić również z rynkiem bukmacherskim. Dzięki temu etap rankingowy pozostaje spójny z końcową próbą ewaluacyjną. Wyniki w tabeli 6.1 pokazują najlepsze konfiguracje wybranych rodzin rankingowych na okresie testowym 2024+.

W tym rozdziale Player Glicko-2 pełni rolę silnego, prostego baseline’u sportowego. Jest to odpowiednik prostego modelu odniesienia: nie wykorzystuje pełnego kontekstu historycznego ani dodatkowego metamodelu, ale pozwala sprawdzić, jak daleko można dojść za pomocą samej chronologicznej oceny siły zawodników.

Tabela 6.1: Najlepsze konfiguracje rodzin rankingowych na okresie testowym 2024+

Rodzina	Najlepsze parametry	AUC	LogLoss	Brier	ECE
Player Glicko-2	$RD = 350$, $vol = 0,06$, okres = 7	0,7511	0,5941	0,2040	0,0443
Player Elo	$K = 48$	0,7348	0,6015	0,2077	0,0283
Player Thurstone– Mosteller	$\beta = 18,75$, $\tau = 0,05$	0,7336	0,6052	0,2084	0,0326
Player Plackett– Luce	$\beta = 18,75$, $\tau = 0,05$	0,7352	0,6134	0,2105	0,0548
Player TrueSkill	$\beta = 4,16$, $\tau = 0,25$	0,7255	0,6224	0,2162	0,0622
Player OpenSkill	$\sigma = 3,50$	0,7337	0,6453	0,2163	0,0834

Wyniki w tabeli 6.1 wskazują, że najlepszym pojedynczym systemem rankingowym jest Player Glicko-2. Model ten osiąga najwyższe AUC oraz najniższy LogLoss spośród analizowanych rankingów również po doborze parametrów. Oznacza to, że przewaga tej rodziny nie wynikała wyłącznie z przypadkowego ustawienia parametrów domyślnych.




Rysunek 6.1: Porównanie jakości rankingów zawodniczych i drużynowych według AUC.


Rysunek 6.1 pokazuje, że ranking oparty na zawodnikach jest zasadniczo silniejszy niż ranking oparty wyłącznie na drużynie. Jest to zgodne ze specyfiką League of Legends: historia organizacji nie zawsze dobrze opisuje aktualny skład, natomiast informacje o zawodnikach lepiej przenoszą się pomiędzy sezonami i transferami.

6.7 Porównanie ratingów z benchmarkiem rynkowym

W porównaniu z benchmarkiem rynkowym Player Glicko-2 osiąga lepszy AUC i LogLoss niż kurs otwarcia oraz wynik zbliżony do kursu zamknięcia. Nie oznacza to jednak, że surowy ranking jest kompletnym modelem predykcyjnym. Rynek bukmacherski pozostaje silnie skalibrowanym benchmarkiem, a surowy ranking ma gorsze ECE niż kursy rynkowe.



Rysunek 6.2: Porównanie AUC rankingów i benchmarków rynkowych na wspólnej próbie.



Rysunek 6.3: Kalibracja wybranych rankingów i benchmarków rynkowych na wspólnej próbie.

Porównanie AUC i wykresów kalibracji prowadzi do dwóch wniosków. Po pierwsze, ranking zawodniczy zawiera silny sygnał sportowy, ponieważ dobrze porządkuje mecze we-

dług prawdopodobieństwa zwycięstwa. Po drugie, sama wartość ratingowa nie wystarcza do uzyskania najlepszej jakości probabilistycznej, ponieważ kalibracja prawdopodobieństw może być gorsza niż w przypadku rynku. Zamiast pełnych krzywych ROC pokazano zestawienie AUC, ponieważ krzywe najlepszych wariantów były bardzo zbliżone i na jednym wykresie praktycznie się nakładały.

6.8 Znaczenie wyników rankingowych dla dalszego modelowania

Wyniki systemów rankingowych uzasadniają budowę metamodelu. Skoro Player Glicko-2 jest silnym pojedynczym sygnałem, może stanowić podstawę modelu wyższego poziomu. Jednocześnie jego ograniczenia kalibracyjne wskazują, że warto połączyć różne informacje rankingowe, niepewność oraz historyczny kontekst formy w jednym modelu probabilistycznym.

Najważniejszy wniosek z tego rozdziału jest zatem dwojaki. Po pierwsze, ranking zawodniczy jest lepszym sposobem reprezentacji siły w League of Legends niż ranking drużynowy. Po drugie, najlepszy pojedynczy ranking nie kończy procesu modelowania, lecz stanowi punkt wyjścia dla metamodelu opisanego w kolejnym rozdziale.

Rozdział 7

Metamodel kontekstowy W20-Binomial

7.1 Motywacja budowy metamodelu

7.1.1 Rola modelu drugiego poziomu

7.1.1.1 Ograniczenia pojedynczych rankingów

W poprzednim rozdziale pokazano, że systemy rankingowe zawodników, szczególnie Player Glicko-2, dostarczają silnego sygnału predykcyjnego. Pojedynczy ranking nie wykorzystuje jednak pełnej informacji dostępnej przed meczem. Nie łączy jednocześnie wielu rodzin ratingów, miar niepewności, historycznej formy drużyn oraz formatu serii Bo1/Bo3/Bo5. Z tego powodu kolejnym etapem pracy jest metamodel, którego zadaniem jest połączenie tych informacji w jedną predykcję probabilistyczną.

7.1.1.2 Stacking jako uzasadnienie konstrukcji modelu

Metamodel jest w tej pracy rozumiany jako model drugiego poziomu. Jego wejściami są predykcje i parametry modeli rankingowych oraz cechy historyczne obliczane wyłącznie na podstawie spotkań rozegranych przed przewidywanym meczem. Takie podejście jest zgodne z ideą stacked generalization, w której predykcje modeli bazowych są wykorzystywane jako cechy dla modelu wyższego poziomu (Wolpert 1992; Breiman 1996).

7.1.2 Definicja wariantu W20-Binomial

Finalnym obiektem modelowania w tym rozdziale jest **W20-Binomial**: kompletny zestaw cech obejmujący predykcje rankingowe, niepewności rankingów, pełny historyczny kontekst drużynowy W20 oraz sygnały rankingowe skorygowane dwumianowo względem formatu serii. Rodzina estymatora nie została założona z góry. Hiperparametry kilku ro-

dzin modeli dobrano za pomocą Optuny, a następnie dostrojone warianty porównano w procedurze walk-forward i miesięcznym bootstrapie blokowym. Ostatecznie najstabilniejszym estymatorem okazała się regresja logistyczna ElasticNet.

7.2 Zestaw cech W20-Binomial

Wszystkie cechy dla meczu t były obliczane wyłącznie z informacji dostępnych przed tym meczem. Model nie korzystał z żadnych statystyk z rozgrywanego spotkania. Zestaw W20-Binomial składa się z czterech grup cech.

7.2.1 Predykcje rankingowe zawodników

Pierwszą grupę stanowią **predykcje rankingowe zawodników**, czyli prawdopodobieństwa zwycięstwa Team 1 wygenerowane przez sześć rodzin rankingowych:

- `player_elo` – Elo,
- `player_g1` – Glicko-2,
- `player_ts` – TrueSkill,
- `player_os` – OpenSkill,
- `player_pl` – Plackett–Luce,
- `player_tm` – Thurstone–Mosteller.

7.2.2 Niepewność ocen i rozkład siły składu

Drugą grupę stanowią **cechy niepewności i rozkładu siły w składzie**. Obejmują one między innymi minimalne ratingi zawodników w Elo, maksymalne ratingi w Glicko-2, średnie odchylenie ratingu Glicko-2 oraz średnie niepewności σ dla rodzin TrueSkill, OpenSkill, Plackett–Luce i Thurstone–Mosteller. Celem tych cech jest opisanie nie tylko średniej siły drużyny, lecz także stabilności i pewności tej oceny.

7.2.3 Historyczny kontekst drużynowy W20

Trzecią grupę stanowi **pełny historyczny kontekst W20**. Dla obu stron meczu agregowano ostatnie 20 wcześniejszych obserwacji danej drużyny. Kontekst obejmuje:

- kroczący współczynnik zwycięstw,
- średnią liczbę zabójstw i śmierci,

- historyczne GD@15,
- DPM i VSPM,
- liczbę zniszczonych wież,
- liczbę Baronów Nashora,
- końcową ilość złota drużyny,
- czas trwania gry.

W dalszej części pracy przez **model kontekstowy** rozumiany jest model wykorzystujący właśnie ten pełny kontekst historyczny. Nie rozdzielano finalnej narracji na wariant podstawowy i pełny; węższe zestawy cech traktowano wyłącznie jako ablacje diagnostyczne.

7.2.4 Cechy dwumianowe dla formatu serii


Czwartą grupę stanowią **cechy dwumianowe** (ang. *binomial features*). Format serii Bo1/Bo3/Bo5 nie został podany modelowi wyłącznie jako surowa liczba. Zamiast tego prawdopodobieństwa rankingowe przekształcono do przybliżonego prawdopodobieństwa wygrania całej serii. Dla serii do n map zastosowano wzór:

$$P(\text{win series}) = \sum_{k=\lfloor n/2 \rfloor + 1}^n \binom{n}{k} p^k (1-p)^{n-k},$$

gdzie p oznacza rankingowe prawdopodobieństwo wygrania pojedynczej mapy lub pojedynczego meczu traktowane jako sygnał bazowy. W praktyce utworzono po jednej cesze dwumianowej dla każdej rodziny rankingowej. Zabieg ten jest istotny, ponieważ dłuższa seria nie tylko informuje o typie meczu, lecz także zmienia wariancję wyniku: silniejsza drużyna powinna mieć większą szansę wygrania Bo3 lub Bo5 niż pojedynczej mapy.

Tabela 7.1: Skład finalnego zestawu cech W20-Binomial

Grupa cech	Skład	Rola w modelu
Predykcje rankingowe	Elo, Glicko-2, TrueSkill, OpenSkill, Plackett–Luce, Thurstone–Mosteller	Bazowy opis relatywnej siły składów
Niepewność rankingów	Minimalne/maksymalne ratingi, RD Glicko-2, średnie σ rodzin probabilistycznych	Informacja o stabilności i pewności oceny
Kontekst W20	Win rate, kills, deaths, GD@15, DPM, VSPM, towers, nashors, gold, duration	Forma, styl, ekonomia, obiekty i tempo gry
Korekta dwumianowa	Sześć prawdopodobieństw rankingowych przekształconych wzorem dwumianowym dla Bo1/Bo3/Bo5	Strukturalne uwzględnienie formatu serii




Rysunek 7.1: Architektura finalnego modelu W20-Binomial. Diagram pokazuje cztery główne grupy informacji wejściowej oraz dwa końcowe etapy postprocessingu: symetryzację predykcji względem kolejności drużyn i kalibrację Platta w schemacie expanding-window.

7.3 Współzależność sygnałów rankingowych

7.3.1 Korelacje pomiędzy rodzinami rankingów

Przed trenowaniem modelu sprawdzono, czy sygnały rankingowe rzeczywiście wnoszą niezależną informację. Wiele systemów rankingowych opisuje tę samą ukrytą wielkość: relatywną siłę drużyny lub zawodników przed meczem. Z tego powodu można oczekiwać wysokich korelacji pomiędzy predykcjami Elo, Glicko-2, TrueSkill, OpenSkill, Plackett–Luce i Thurstone–Mosteller.



Rysunek 7.2: Macierz korelacji głównych sygnałów rankingowych.

Macierz na rysunku 7.2 pokazuje bardzo silną współzależność wielu ratingów. Nie oznacza to, że cechy rankingowe są bezużyteczne; przeciwnie, pokazuje, że zawierają podobny sygnał sportowy. Oznacza jednak, że model liniowy powinien być regularyzowany, a interpretacja pojedynczych współczynników musi być ostrożna.

7.3.2 Analiza VIF i konsekwencje dla modelu liniowego

Drugim krokiem była analiza VIF, czyli variance inflation factor. Wysoki VIF wskazuje na silną współliniowość i może prowadzić do niestabilnych współczynników w modelach

liniowych.

Tabela 7.2: Najwyższe wartości VIF dla sygnałów rankingowych

Sygnał rankingowy	VIF
Team Thurstone–Mosteller	337,6
Team OpenSkill	222,3
Team Glicko-2	143,4
Player OpenSkill	132,6
Player Thurstone–Mosteller	126,4
Player Plackett–Luce	124,5
Team TrueSkill	109,4
Team Plackett–Luce	106,3
Player Elo	59,7
Team Elo	41,4
Player TrueSkill	25,4
Player Glicko-2	13,2

Wyniki w tabeli 7.2 potwierdzają, że część sygnałów rankingowych jest silnie współliniowa. W pracy nie potraktowano tego jako powodu do ręcznego usunięcia całych rodzin ratingów, ponieważ podobne systemy mogą nadal wносить niewielkie, ale użyteczne różnice w konkretnych okresach, ligach lub składach. Wniosek z analizy VIF jest zatem metodologiczny: finalny metamodel powinien wykorzystywać regularyzację oraz powinien być oceniany przede wszystkim przez jakość predykcji out-of-time, a nie przez bezpośrednią interpretację pojedynczych współczynników.

Z tego powodu w dalszych eksperymentach zastosowano regresję logistyczną ElasticNet oraz porównano ją z modelami nieliniowymi w procedurze walk-forward. Regularyzacja ElasticNet ogranicza wpływ współliniowości przez zmniejszanie wag podobnych cech i częściową selekcję sygnałów, natomiast bootstrap blokowy sprawdza, czy uzyskana przewaga nie wynika z jednej niestabilnej konfiguracji danych. Analiza VIF pełni więc rolę uzasadnienia wyboru regularyzowanego estymatora i ostrożnej interpretacji wag modelu, a nie osobnego kryterium eliminacji cech.

7.4 Dobór długości okna historycznego

Osobno sprawdzono długość okna historycznego dla pełnego kontekstu drużynowego. Testowano okna W3, W5, W10, W20 oraz W50. Krótsze okna szybciej reagują na zmianę formy, lecz są bardziej podatne na szum pojedynczych meczów. Dłuższe okna są stabilniejsze, ale mogą mieszać aktualną formę z nieaktualnymi składami, patchami lub stylami

gry.

Tabela 7.3: Wpływ długości okna historycznego na jakość metamodelu

Okno	AUC	LogLoss	Brier	ECE
W3	0,7470	0,5928	0,2036	0,0131
W5	0,7476	0,5924	0,2035	0,0108
W10	0,7477	0,5925	0,2034	0,0088
W20	0,7492	0,5910	0,2028	0,0088
W50	0,7489	0,5915	0,2030	0,0124

Najniższy LogLoss w tej ablacji uzyskało okno W20. Różnica względem W50 nie jest duża, ale W20 lepiej odpowiada finalnej interpretacji modelu: ma reprezentować aktualną formę, styl i tempo drużyny, bez nadmiernego obciążenia starszymi meczami. Dlatego w dalszych eksperymentach jako główny wariant kontekstu przyjęto W20.

7.5 Dobór rodziny estymatora po strojeniu hiperparametrów


Ostatnim krokiem wyboru architektury było porównanie kilku rodzin modeli na tym samym kompletnym zestawie cech W20-Binomial. Hiperparametry dla każdej rodziny dobrano za pomocą Optuny na chronologicznym zbiorze walidacyjnym. Wyników samej walidacji Optuny nie traktowano jako finalnej tabeli rezultatów; Optuna pełniła funkcję strojenia hiperparametrów. Dopiero dostrojone warianty oceniono w schemacie walk-forward, który lepiej odpowiada rzeczywistemu użyciu modelu w czasie.

Porównano regresję logistyczną ElasticNet, ExtraTrees, LightGBM, HistGradientBoosting oraz małą sieć MLP. Wszystkie modele korzystały z tego samego zestawu cech W20-Binomial i były trenowane w schemacie expanding-window z aktualizacją co 1000 meczów.

Tabela 7.4: Porównanie dostrojonych rodzin modeli W20-Binomial w procedurze walk-forward

Model	AUC	LogLoss	Brier	ECE
LR ElasticNet	0,7553	0,5858	0,2007	0,0130
ExtraTrees	0,7505	0,5896	0,2024	0,0121
LightGBM	0,7507	0,5897	0,2024	0,0110
HistGradientBoosting	0,7502	0,5904	0,2026	0,0100
MLP	0,7456	0,5952	0,2046	0,0201

Najniższy LogLoss i najwyższy AUC uzyskała regresja logistyczna ElasticNet. Modele nieliniowe miały miejscami lepsze ECE, lecz zgodnie z hierarchią metryk głównym kryterium wyboru pozostaje LogLoss, ponieważ bezpośrednio mierzy jakość prognozy probabilistycznej i silnie karze błędną pewność.



Rysunek 7.3: Miesięczny bootstrap blokowy różnic LogLoss dostrojonych modeli względem regresji logistycznej ElasticNet.

Bootstrap blokowy przedstawiony na rysunku 7.3 potwierdza stabilność przewagi modelu liniowego. Wszystkie testowane warianty nieliniowe miały dodatnie przedziały ufności dla różnicy LogLoss względem regresji logistycznej ElasticNet. Różnice wynosiły odpowiednio około 0,0038 dla ExtraTrees, 0,0039 dla LightGBM, 0,0045 dla HistGradientBoosting oraz 0,0094 dla MLP. Oznacza to, że wybór regresji logistycznej nie wynika wyłącznie z pojedynczej tabeli metryk, lecz jest stabilny względem miesięcznego resamplingu.

7.6 Ablacje finalnego estymatora: masking i sygnał Glicko-2

Po wyborze regresji logistycznej ElasticNet jako finalnej rodziny estymatora przeprowadzono dodatkowe ablacje wyjaśniające, z których sygnałów korzysta model. Taka kolejność jest istotna: najpierw wybrano klasę modelu na kompletnym zestawie cech W20-Binomial, a dopiero następnie sprawdzono wrażliwość wybranego estymatora na maskowanie i usuwanie wybranych grup rankingowych. Szczególnie ważny był test zależności od rodziny Glicko-2, ponieważ w rozdziale rankingowym Player Glicko-2 był najlepszym pojedynczym sygnałem.

Tabela 7.5: Masking i ablacja sygnału Player Glicko-2 w modelu kontekstowym

Wariant	AUC	LogLoss	ECE	Δ LogLoss
Pełny model kontekstowy	0,7555	0,5855	0,0118	0,0000
G2 + context	0,7551	0,5861	0,0102	0,0005
Mask all 10%	0,7537	0,5868	0,0085	0,0012
Mask G2 10%	0,7527	0,5875	0,0089	0,0020
Mask G2 30%	0,7516	0,5884	0,0110	0,0028
No player_gl	0,7501	0,5898	0,0130	0,0042
No G2 family	0,7470	0,5925	0,0119	0,0070


Eksperyment potwierdza, że Player Glicko-2 jest najważniejszym pojedynczym sygnałem, ale pełny model korzysta również z informacji zastępczej zawartej w pozostałych rankingach. Maskowanie cech w danych treningowych nie poprawiło wyniku, dlatego nie zostało włączone do finalnego estymatora. Ablacja pełni jednak ważną funkcję kontrolną: pokazuje, że model nie jest arbitralną czarną skrzynką, lecz wykorzystuje przewidywalną strukturę sygnałów rankingowych.

Osobno sprawdzono, czy do finalnego wejścia warto dodać predykcje i parametry rankingów drużynowych. Wariant rozszerzony Player+Team W20-Binomial uzyskał minimalnie niższy LogLoss niż wariant player-based, ale różnica była bardzo mała i nie została potwierdzona w miesięcznym bootstrapie blokowym. Wynik przedstawiono w tabeli 7.6. Z tego powodu finalny model zachowuje prostszą strukturę: komponent rankingowy opiera się na sygnałach zawodniczych, natomiast informacja drużynowa jest reprezentowana przez pełny kontekst historyczny W20.

Tabela 7.6: Ablacja dodania rankingów drużynowych do finalnego wejścia W20-Binomial

Wariant	AUC	LogLoss	Brier	ECE
Player-based W20-Binomial	0,7553	0,5858	0,2007	0,0131
Player+Team W20-Binomial	0,7554	0,5857	0,2007	0,0144

W miesięcznym bootstrapie blokowym różnica $\Delta = \text{LogLoss}_{\text{Player+Team}} - \text{LogLoss}_{\text{Player}}$ wyniosła $-0,0001$, a przedział ufności 95% był równy $[-0,0002, 0,0020]$. Ponieważ przedział obejmuje zero, dodatkowe cechy team-based potraktowano jako zwiększenie złożoności bez stabilnej poprawy jakości predykcji.



Rysunek 7.4: Miesięczny bootstrap blokowy różnic LogLoss wariantów maskingu względem pełnego modelu kontekstowego.

7.7 Symetryzacja kolejności drużyn

7.7.1 Źródło asymetrii technicznej

Regresja logistyczna trenowana na wektorze cech zależnym od kolejności stron meczu generuje predykcję dla zdarzenia, że wygra strona zapisana jako Team 1. Problem ten jest technicznie naturalny, ponieważ dane wejściowe mają postać różnic lub par cech Team 1–Team 2. Jednocześnie z perspektywy sportowej prawdopodobieństwo powinno spełniać warunek antysymetrii: jeżeli ten sam mecz zostanie zapisany w odwróconej kolejności, to prawdopodobieństwo zwycięstwa pierwszej strony powinno być dopełnieniem poprzedniej predykcji.

7.7.2 Procedura uśredniania predykcji

W praktyce sprawdzono, że surowy estymator nie jest idealnie niewrażliwy na kolejność drużyn. Dla każdego meczu wygenerowano więc dwie predykcje: predykcję w oryginalnej orientacji oraz predykcję po zamianie stron. Predykcję po zamianie stron przeliczono z powrotem na prawdopodobieństwo zwycięstwa pierwotnej strony, a następnie uśredniono oba oszacowania:

$$p_{sym}(A > B) = \frac{p_{orig}(A > B) + (1 - p_{swap}(B > A))}{2}. \quad (7.1)$$

Tak zdefiniowany wariant zachowuje informację wyuczoną przez regresję logistyczną,

ale ogranicza artefakt wynikający z arbitralnego zapisu meczu. Diagnostyka wrażliwości kolejności wykazała średnią bezwzględną różnicę prawdopodobieństw równą około 0,0287, medianę 0,0237 oraz maksimum 0,2113. Po symetryzacji surowy model uzyskał AUC 0,7561 i LogLoss 0,5858, nieznacznie poprawiając rozróżnianie względem predykcji w oryginalnej orientacji. Wniosek z tej analizy jest metodologiczny: model końcowy powinien respektować symetrię problemu, nawet jeżeli sama poprawa metryk jest niewielka.

7.8 Kalibracja prawdopodobieństw

7.8.1 Schemat expanding-window


Ponieważ celem pracy jest predykcja probabilistyczna, końcowy wariant modelu poddano dodatkowej analizie kalibracji. Porównano predykcje surowe, kalibrację Platta oraz kalibrację izotoniczną. Obie metody były stosowane w schemacie expanding-window: kalibrator dla danego folda uczono wyłącznie na wcześniejszych foldach, bez wykorzystania przyszłych obserwacji. Dzięki temu kalibracja zachowuje chronologiczny charakter ewaluacji.

7.8.2 Porównanie Platta i kalibracji izotonicznej


Kalibracja Platta polegała na dopasowaniu regresji logistycznej do logitu surowych prawdopodobieństw modelu. Jej zaletą jest mała liczba parametrów i odporność na mniejsze próbki kalibracyjne. Kalibracja izotoniczna jest bardziej elastyczna, ale może łatwiej dopasować lokalny szum, szczególnie przy dryfie danych i nierównej liczbie obserwacji w kolejnych okresach.

Tabela 7.7: Porównanie wariantów symetryzacji i kalibracji na wspólnej próbie rynkowej

Wariant	AUC	LogLoss	Brier	ECE
Symetryczny + Platt expanding	0,7551	0,5854	0,2007	0,0100
Oryginalny + Platt expanding	0,7542	0,5862	0,2010	0,0098
Symetryczny surowy	0,7551	0,5867	0,2011	0,0193
Oryginalny surowy	0,7543	0,5868	0,2011	0,0125
Symetryczny + isotonic expanding	0,7532	0,5901	0,2013	0,0097
Oryginalny + isotonic expanding	0,7519	0,5906	0,2018	0,0104



Rysunek 7.5: Porównanie wariantów symetryzacji i kalibracji według LogLoss na wspólnej próbie rynkowej.



Rysunek 7.6: Porównanie wariantów symetryzacji i kalibracji według ECE na wspólnej próbie rynkowej.

Najniższy LogLoss uzyskał wariant symetryczny z kalibracją Platt. Kalibracja izotoniczna dawała bardzo niskie ECE, ale pogarszała LogLoss i AUC. Zgodnie z hierarchią metryk przyjętą w pracy wybrano więc wariant Platt: poprawiał kalibrację względem surowego modelu, a jednocześnie nie obniżał jakości probabilistycznej mierzonej główną metryką. Ostateczny model kierowany do porównania z benchmarkami rynkowymi to **skalibrowany symetryczny LR-ElasticNet-W20-Binomial**.

7.9 Wnioski z etapu metamodelowania

Etap metamodelowania prowadzi do sześciu głównych wniosków. Po pierwsze, cechy zawodnicze pozostają najważniejszą podstawą predykcji, a Player Glicko-2 jest najsilniejszym pojedynczym sygnałem rankingowym. Po drugie, pełny kontekst W20 uzupełnia rankingi o informacje o aktualnej formie, stylu, ekonomii, obiektach i tempie gry. Po trzecie, format serii Bo1/Bo3/Bo5 najlepiej uwzględnić strukturalnie przez transformację dwumianową prawdopodobieństw rankingowych. Po czwarte, mimo przetestowania modeli drzewiastych i MLP, najlepiej generalizującym estymatorem okazała się regularyzowana regresja logistyczna ElasticNet. Po piąte, finalny model powinien respektować symetrię problemu względem kolejności drużyn. Po szóste, kalibracja Platt'a poprawia jakość prawdopodobieństw bez pogorszenia LogLoss, dlatego została użyta w wariancie końcowym.

Najważniejszym rezultatem tego rozdziału jest wybór modelu głównego do porównania z benchmarkami bukmacherskimi: **skalibrowanego symetrycznego LR-ElasticNet-W20-Binomial**. Model ten będzie w następnym rozdziale oceniony na wspólnej próbie meczów posiadających zarówno dane sportowe, jak i kursy bukmacherskie.

Rozdział 8

Ocena końcowa i porównanie z rynkiem bukmacherskim

8.1 Cel porównania końcowego

8.1.1 Zakres ewaluacji

8.1.1.1 Wspólna próba sportowo-rynkowa

Ostatni etap empiryczny zestawia końcowy model sportowy z benchmarkami rankingowymi, modelami pomocniczymi oraz rynkiem bukmacherskim. Porównanie wykonano na wspólnej próbie meczów, dla których dostępne były zarówno dane GOL.GG, jak i kursy OddsPortal. Dzięki temu każdy wariant oceniono na identycznym zbiorze obserwacji oraz przy tej samej orientacji stron meczu.

8.1.1.2 Predykcja probabilistyczna zamiast decyzji finansowej

Rozdział dotyczy jakości predykcji probabilistycznej. Kursy bukmacherskie pełnią funkcję punktu odniesienia, ponieważ są skondensowaną rynkową oceną prawdopodobieństwa wyniku. Nie analizowano jednak strategii obstawiania, stawek, zwrotu z inwestycji ani zarządzania kapitałem. Wnioski należy więc interpretować jako porównanie jakości prawdopodobieństw na próbie historycznej.

8.2 Porównywane warianty

8.2.1 Model finalny i warianty kontrolne

8.2.1.1 Sym-Cal jako wariant promowany

W końcowym porównaniu uwzględniono następujące warianty:

- **Sym-Cal LR-ElasticNet-W20-Binomial**, czyli finalny model pracy: regresję logistyczną ElasticNet na zestawie W20-Binomial, z symetryzacją kolejności drużyn i kalibracją Plattą w schemacie expanding-window,
- **LR-ElasticNet-W20-Binomial (raw)**, czyli poprzedni surowy wariant regresji logistycznej bez końcowej symetryzacji i kalibracji,
- **ExtraTrees-W20-Binomial, LightGBM-W20-Binomial, HGB-W20-Binomial i MLP-W20-Binomial**, czyli dostrojone warianty nieliniowe używane jako kontrola wyboru rodziny estymatora,
- **Player Glicko-2**, czyli najlepszy pojedynczy system rankingowy,
- **Mkt Open**, czyli prawdopodobieństwa implikowane przez kursy otwarcia,
- **Mkt Close**, czyli prawdopodobieństwa implikowane przez kursy zamknięcia.

8.2.1.2 Znaczenie kursu otwarcia i zamknięcia

Kurs otwarcia jest benchmarkiem bliższym perspektywie wcześniejszej prognozy przedmeczowej, natomiast kurs zamknięcia jest silniejszym benchmarkiem diagnostycznym, ponieważ może zawierać późniejsze informacje rynkowe. Surowy wariant LR pozostawiono w tabeli, aby bezpośrednio pokazać efekt końcowej symetryzacji i kalibracji.

8.3 Wyniki na wspólnej próbie


8.3.1 Główna tabela metryk

8.3.1.1 Jednolity zbiór obserwacji

Końcowa wspólna próba obejmowała 11609 meczów. Jest to ścisła przecięta próba sportowo-rynkowa, dlatego różni się od niektórych wcześniejszych diagnostyk kalibracji, które obejmowały nieco więcej obserwacji. W tej części pracy cytowane są wyłącznie wartości z końcowej próby wspólnej.

Tabela 8.1: Końcowe porównanie finalnego modelu, wariantów pomocniczych i benchmarków rynkowych

Model	AUC	LogLoss	Brier	ECE
Sym-Cal LR-ElasticNet-W20-Binomial	0,7551	0,5854	0,2007	0,0100
LR-ElasticNet-W20-Binomial (raw)	0,7543	0,5868	0,2011	0,0125
ExtraTrees-W20-Binomial	0,7495	0,5906	0,2028	0,0120
LightGBM-W20-Binomial	0,7496	0,5907	0,2028	0,0110
HGB-W20-Binomial	0,7492	0,5913	0,2030	0,0100
Player Glicko-2	0,7488	0,5950	0,2045	0,0317
MLP-W20-Binomial	0,7446	0,5961	0,2050	0,0201
Mkt Close	0,7420	0,5978	0,2057	0,0138
Mkt Open	0,7337	0,6047	0,2088	0,0183



Rysunek 8.1: Porównanie końcowych modeli według LogLoss na wspólnej próbie.

8.3.1.2 Interpretacja przewagi LogLoss

Tabela 8.1 oraz rysunek 8.1 pokazują, że najniższy LogLoss uzyskał skalibrowany symetryczny LR-ElasticNet-W20-Binomial. Względem surowego wariantu regresji logistycznej poprawa wyniosła około 0,0014 LogLoss. Różnica jest niewielka w skali bezwzględnej, ale istotna metodologicznie: końcowy model jednocześnie respektuje symetrię problemu i poprawia kalibrację prawdopodobieństw.

Najważniejszy wynik końcowy pozostaje stabilny: finalny model uzyskał niższy LogLoss niż Player Glicko-2, Market Open, Market Close oraz wszystkie dostrojone warianty nieliniowe trenowane na tym samym zestawie cech. Oznacza to, że końcowa poprawa nie zmieniła wniosku o przewadze modelu liniowego, lecz go wzmocniła.

8.4 Istotność różnic LogLoss

8.4.1 Definicja różnicy strat

Zgodnie z procedurą opisaną w rozdziale metodologicznym, końcowe różnice LogLoss zweryfikowano miesięcznym bootstrapem blokowym. Dla każdego meczu obliczono:


$$d_i = \ell_{benchmark,i} - \ell_{model,i}.$$

Wartość dodatnia oznacza, że finalny model uzyskał niższą stratę niż benchmark. Wyniki bootstrapu przedstawiono w tabeli 8.2.

Tabela 8.2: Miesięczny bootstrap blokowy różnic LogLoss względem modelu Sym-Cal LR-ElasticNet-W20-Binomial

Porównanie	Różnica LogLoss	95% CI	p jednostronne
Mkt Open	0,0193	[0,0108; 0,0283]	0,0001
Mkt Close	0,0124	[0,0042; 0,0214]	0,0010
MLP-W20-Binomial	0,0107	[0,0072; 0,0144]	0,0001
Player Glicko-2	0,0096	[0,0064; 0,0129]	0,0001
HGB-W20-Binomial	0,0059	[0,0035; 0,0082]	0,0001
LightGBM-W20-Binomial	0,0053	[0,0032; 0,0074]	0,0002
ExtraTrees-W20-Binomial	0,0053	[0,0028; 0,0077]	0,0001
LR-ElasticNet-W20-Binomial	0,0014	[0,0004; 0,0024]	0,0031
(raw)			


8.4.2 Przedziały ufności bootstrapu blokowego



Rysunek 8.2: Przedziały ufności dla różnic LogLoss w miesięcznym bootstrapie blokowym względem finalnego modelu symetrycznego i skalibrowanego.

Wszystkie przedziały ufności w tabeli 8.2 są dodatnie. Dotyczy to zarówno benchmarków rynkowych, jak i surowego wariantu regresji logistycznej. Oznacza to, że symetryzacja i kalibracja Platt'a poprawiły model względem poprzedniej wersji, a finalny wariant zachował przewagę nad pozostałymi punktami odniesienia.

8.4.3 AUC jako metryka pomocnicza



Rysunek 8.3: Porównanie końcowych modeli według AUC na wspólnej próbie.

AUC potwierdza, że końcowy model dobrze porządkuje mecze według prawdopodobieństwa zwycięstwa. Najważniejsza przewaga pracy nie polega jednak wyłącznie na lepszym rankingu obserwacji, lecz na poprawie jakości prawdopodobieństw mierzonej LogLoss i Brier Score.


8.5 Analiza segmentowa według formatu serii

8.5.1 Definicja przewagi segmentowej

Ponieważ format serii wpływa na charakter problemu predykcyjnego, końcowy model porównano z benchmarkami także osobno dla Bo1, Bo3 i Bo5. Przewagę modelu przedstawiono jako różnicę LogLoss pomiędzy benchmarkiem i finalnym modelem:

$$\Delta_{BoN} = \text{LogLoss}_{\text{benchmark}, BoN} - \text{LogLoss}_{\text{model}, BoN}.$$

Wartość dodatnia oznacza, że model Sym-Cal LR-ElasticNet-W20-Binomial uzyskał niższy LogLoss w danym segmencie.



Rysunek 8.4: Przewaga finalnego modelu symetrycznego i skalibrowanego nad benchmarkami według formatu serii. Wartości dodatnie oznaczają niższy LogLoss modelu.

8.5.2 Wyniki segmentowe

8.5.2.1 LogLoss według długości serii

Tabela 8.3: LogLoss finalnego modelu i benchmarków według formatu serii

Format	Mecze	Model	Mkt Open	Mkt Close	Player Glicko-2
Bo1	7 229	0,5994	0,6150	0,6068	0,6057
Bo3	3 117	0,5424	0,5665	0,5604	0,5571
Bo5	1 263	0,6113	0,6398	0,6382	0,6268

8.5.2.2 Ostrożność interpretacji segmentu Bo5


Rysunek 8.4 i tabela 8.3 pokazują przewagę modelu we wszystkich formatach. Największa różnica względem Market Close występuje w Bo5: 0,6113 wobec 0,6382 LogLoss. Segment Bo5 jest jednak najmniejszy i obejmuje głównie mecze play-off, dlatego wynik ten należy traktować jako diagnozę segmentową, a nie jako podstawę osobnej interpretacji przyczynowej.

8.6 Znaczenie kalibracji

8.6.1 Porównanie surowego i skalibrowanego modelu

8.6.1.1 Wpływ na LogLoss i ECE

Końcowa kalibracja zmienia interpretację modelu. Surowy wariant LR-ElasticNet-W20-Binomial uzyskał LogLoss 0,5868 i ECE 0,0125, natomiast wariant symetryczny z kalibracją Platt'a uzyskał LogLoss 0,5854 i ECE 0,0100. Poprawa ECE jest istotna, ponieważ model końcowy ma dostarczać wiarygodne prawdopodobieństwa, a nie tylko klasyfikować zwycięzcę.



Rysunek 8.5: Porównanie końcowych modeli według ECE na wspólnej próbie.

8.6.1.2 Dlaczego ECE nie jest jedynym kryterium

Najniższe ECE w końcowym zestawieniu uzyskał HGB-W20-Binomial, a bardzo niskie ECE miały również LightGBM i finalny model symetryczny. Nie wystarczyło to jednak do wyboru wariantów drzewiastych, ponieważ ich LogLoss był wyraźnie gorszy. Zgodnie z hierarchią metryk przyjętą w pracy głównym kryterium wyboru pozostaje LogLoss, natomiast ECE pełni funkcję pomocniczą. W tym sensie kalibracja Platt'a jest korzystna: poprawia ECE i Brier Score, nie obniżając głównej jakości probabilistycznej.

8.7 Weryfikacja hipotez badawczych

8.7.1 Tabela weryfikacyjna

Na podstawie wyników z poprzednich rozdziałów i końcowego porównania można odnieść się do hipotez sformułowanych we wstępie.

Tabela 8.4: Weryfikacja hipotez badawczych

Hipoteza	Treść	Ocena
H1	Ranking zawodniczy osiąga lepsze wyniki niż ranking drużynowy.	Potwierdzona
H2	Metamodel poprawia jakość probabilistyczną względem pojedynczego rankingu.	Potwierdzona
H3	Dodanie pełnego historycznego kontekstu W20 poprawia interpretację i wspiera jakość modelu względem wariantów bez kontekstu.	Potwierdzona
H4	Model sportowy jest konkurencyjny względem benchmarku bukmacherskiego.	Potwierdzona na badanej próbie

8.7.2 Interpretacja hipotezy rynkowej

W przypadku H4 należy zachować ostrożność interpretacyjną. Wyniki pokazują przewagę finalnego modelu w metrykach probabilistycznych nad benchmarkami rynkowymi na historycznej wspólnej próbie. Nie oznaczają jednak automatycznie możliwości uzyskania dodatniego wyniku finansowego ani trwałej przewagi nad rynkiem w warunkach rzeczywistych. Do takiej oceny potrzebne byłyby osobne eksperymenty dotyczące cen wykonania, kosztów transakcyjnych, limitów, płynności oraz walidacji przyszłościowej.

8.8 Wnioski z porównania końcowego

8.8.1 Syntetyczna odpowiedź empiryczna

8.8.1.1 Przewaga predykcyjna modelu Sym-Cal

Końcowe porównanie pokazuje, że skalibrowany symetryczny LR-ElasticNet-W20-Binomial osiąga najniższy LogLoss na wspólnej próbie sportowo-rynkowej i istotnie przewyższa Market Open, Market Close oraz Player Glicko-2. Poprawa względem surowego modelu jest mała, ale dodatnia i stabilna w miesięcznym bootstrapie blokowym. Wybór finalnego wariantu jest więc uzasadniony zarówno merytorycznie, przez zgodność z symetrią problemu, jak i empirycznie, przez niższy LogLoss oraz lepszą kalibrację.

8.8.1.2 Ograniczenie interpretacji rynkowej

Nie oznacza to dowodu słabości rynku ani skuteczności strategii bukmacherskiej. Kursy pozostają silnym benchmarkiem i mogą uwzględniać informacje niedostępne w danych sportowych, takie jak absencje, przygotowanie drużyn lub zmiany organizacyjne.

Wniosek końcowy dotyczy jakości predykcyjnej na analizowanej próbie historycznej.

Rozdział 9

Dyskusja

9.1 Interpretacja najważniejszych wyników

9.1.1 Znaczenie modelowania na poziomie zawodników

Najbardziej spójnym wynikiem pracy jest przewaga systemów rankingowych liczonych na poziomie zawodników nad rankingami liczonymi wyłącznie na poziomie organizacji. Jest to zgodne ze specyfiką profesjonalnego *League of Legends*. Drużyna nie jest stabilną jednostką w takim samym sensie jak klub w wielu tradycyjnych dyscyplinach sportowych: składy zmieniają się pomiędzy splitami, zawodnicy przechodzą między regionami, a siła organizacji może szybko spaść lub wzrosnąć po transferach. Ranking drużynowy agreguje te zmiany z opóźnieniem, natomiast ranking zawodniczy może przynosić część informacji o jakości gracza po zmianie zespołu.

Nie oznacza to, że sama suma ratingów zawodników w pełni opisuje siłę drużyny. Wyniki metamodelu pokazują raczej, że ratingi zawodnicze są najlepszym fundamentem, ale wymagają uzupełnienia o kontekst historyczny i informacje o formacie serii. W praktyce pięciu silnych zawodników nie zawsze tworzy równie silny zespół, a krótko- i średnioterminowa forma może wpływać na wynik niezależnie od długookresowej oceny siły.

9.1.2 Rola metamodelu W20-Binomial

Metamodel W20-Binomial poprawił jakość probabilistyczną względem najlepszego pojedynczego rankingu. Interpretacyjnie oznacza to, że predykcja meczu nie powinna opierać się wyłącznie na jednym systemie ratingowym. Różne rodziny rankingów opisują podobną ukrytą siłę sportową, ale robią to z inną dynamiką aktualizacji i innym sposobem traktowania niepewności. Połączenie tych sygnałów z kroczącymi statystykami drużynowymi pozwala modelowi odróżnić samą siłę składu od bieżącej formy, stylu gry i kontekstu serii.

Wybór regresji logistycznej ElasticNet jako najlepszego estymatora wskazuje, że zasadnicza część informacji była już zawarta w skonstruowanych cechach. Bardziej złożone

modele nieliniowe nie poprawiły LogLoss, mimo że miały większą elastyczność. W tym sensie wynik wspiera podejście inżynierskie oparte na starannej konstrukcji cech, kontroli chronologii i regularyzacji, a nie wyłącznie na zwiększaniu złożoności estymatora.

9.1.3 Symetryzacja i kalibracja jako końcowe uporządkowanie modelu

Końcowa symetryzacja oraz kalibracja Platt’a przyniosły niewielką, ale stabilną poprawę względem surowego wariantu regresji logistycznej. Skala tej poprawy nie powinna być interpretowana jako przełomowy skok jakościowy. Jej znaczenie jest przede wszystkim metodologiczne: model końcowy lepiej respektuje symetrię problemu, w którym zamiana kolejności drużyn nie powinna zmieniać sensu predykcji, oraz generuje bardziej wiarygodne prawdopodobieństwa.

Warto podkreślić, że kalibracja izotoniczna uzyskała bardzo dobre wartości ECE, ale pogorszyła LogLoss i AUC. Z tego powodu nie została wybrana jako wariant finalny. Decyzja ta jest konsekwencją hierarchii metryk przyjętej w pracy: głównym kryterium jest jakość probabilistyczna mierzona LogLoss, natomiast ECE pełni funkcję diagnostyczną. Skalowanie Platt’a okazało się lepszym kompromisem pomiędzy kalibracją a stabilnością predykcji.

9.2 Interpretacja porównania z rynkiem bukmacherskim

9.2.1 Rynek jako silny benchmark probabilistyczny

Kursy bukmacherskie są trudnym punktem odniesienia, ponieważ agregują wiele źródeł informacji: modele analityczne, wiedzę ekspertów, reakcje uczestników rynku oraz aktualizacje cen przed meczem. Szczególnie kurs zamknięcia może zawierać informacje niedostępne w danych sportowych wykorzystanych w tej pracy. Z tego powodu porównanie z Market Close jest bardziej wymagające niż porównanie z prostym benchmarkiem rankingowym.

Finalny model uzyskał niższy LogLoss zarówno od Market Open, jak i Market Close na wspólnej próbie historycznej. Wynik ten jest istotny, ponieważ wskazuje, że połączenie ratingów zawodniczych i kontekstu historycznego może przypisywać wynikom prawdopodobieństwa konkurencyjne względem publicznego benchmarku rynkowego. Jednocześnie przewaga ta powinna być interpretowana ostrożnie: dotyczy konkretnej próby, konkretnego sposobu normalizacji kursów i konkretnego horyzontu danych.

9.2.2 Granice wniosku rynkowego

Niższy LogLoss od benchmarku kursowego nie jest równoznaczny z możliwością osiągnięcia zysku z zakładów. Ewaluacja probabilistyczna i strategia finansowa są odrębnymi problemami. Analiza finansowa wymagałaby uwzględnienia marży, podatków, limitów, płynności, dostępności kursów w czasie rzeczywistym, opóźnień wykonania oraz reguł zarządzania ryzykiem. Te elementy nie były przedmiotem pracy.

Dlatego właściwy wniosek jest węższy: na badanej próbie historycznej model sportowy uzyskał lepsze metryki probabilistyczne niż znormalizowane prawdopodobieństwa implikowane przez kursy. Jest to wynik dotyczący jakości predykcyjnej, a nie ekonomicznej przewagi nad rynkiem.

9.3 Ograniczenia badania

9.3.1 Zakres i reprezentatywność danych

Pierwszym ograniczeniem jest zależność wyników od dostępnych źródeł danych. Dane GOL.GG dostarczają bogatego opisu sportowego, ale nie obejmują wszystkich czynników wpływających na wynik meczu. W szczególności brakuje informacji jakościowych o problemach organizacyjnych, chorobach, treningach, komunikacji drużyn, przygotowaniu strategicznym oraz szczegółowym stanie mety w danym patchu. Część tych informacji może być pośrednio uwzględniana przez rynek kursów, ale nie występuje jawnie w zbiorze sportowym.

Drugim ograniczeniem jest fakt, że końcowa próba rynkowa obejmuje tylko mecze posiadające kursy bukmacherskie. Jest to konieczne dla uczciwego porównania z rynkiem, ale zawęża interpretację wyników. Mecze z kursami mogą różnić się od całej populacji meczów GOL.GG: częściej dotyczą ważniejszych lig, bardziej rozpoznawalnych drużyn i spotkań o większym zainteresowaniu.

9.3.2 Dryf czasowy i zmiany środowiska gry

League of Legends jest środowiskiem niestacjonarnym. Aktualizacje gry, zmiany mety, przebudowy składów i zmiany formatu rozgrywek mogą wpływać na zależności obserwowane w danych historycznych. Procedura walk-forward ogranicza ryzyko przecieku informacji z przyszłości, ale nie usuwa problemu dryfu danych. Model oceniony historycznie może wymagać okresowej aktualizacji i ponownej walidacji w kolejnych sezonach.

Szczególnie trudne są okresy po dużych zmianach patcha lub po przerwach między sezonami, gdy dotychczasowe ratingi i cechy historyczne mogą słabiej opisywać aktualną siłę drużyn. Z tego powodu wyniki należy traktować jako ocenę na analizowanym horyzoncie, a nie jako gwarancję stałej skuteczności w przyszłości.

9.3.3 Ograniczenia konstrukcji cech

Model wykorzystuje historyczny kontekst W20, rankingowe predykcje bazowe, miary niepewności oraz korektę formatu serii. Nie wykorzystuje natomiast pełnego opisu draftu bohaterów ani szczegółowych interakcji pomiędzy rolami. W praktyce siła drużyny może zależeć od dopasowania stylów gry, synergii zawodników, preferencji bohaterów i zdolności adaptacji do przeciwnika. Te elementy są tylko częściowo reprezentowane przez statystyki historyczne.

Ograniczeniem jest również agregacja informacji na poziomie drużyny i zawodników. Ranking zawodniczy poprawia opis transferów, ale nie modeluje wprost relacji pomiędzy konkretną piątką graczy. Dwie drużyny o podobnej sumarycznej sile zawodników mogą różnić się zgraniem, komunikacją lub dopasowaniem ról. To wskazuje na potencjalną wartość przyszłych cech opisujących stabilność składu i doświadczenie wspólnej gry.

9.4 Implikacje dla dalszych badań

9.4.1 Rozszerzenie danych przedmeczowych

Najbardziej naturalnym kierunkiem rozwoju jest rozszerzenie danych o informacje dostępne przed meczem, ale nieuwzględnione w obecnym zbiorze. Szczególnie ważny może być draft bohaterów, kontekst patcha, absencje, zmiany składu oraz bardziej szczegółowe informacje o historii wspólnej gry zawodników. Takie dane mogłyby poprawić model zwłaszcza w meczach, w których różnica ratingów jest niewielka.

9.4.2 Walidacja przyszłościowa

Drugim kierunkiem jest rygorystyczna walidacja przyszłościowa. Najsilniejszym testem byłoby zamrożenie procesu konstrukcji cech, hiperparametrów i procedury kalibracji, a następnie ocena na pełnym kolejnym sezonie, który nie był użyty ani w eksploracji, ani w doborze modelu. Pozwoliłoby to lepiej ocenić odporność metamodelu na dryf danych i zmiany środowiska gry.

9.4.3 Lepsze modelowanie składu i synergii

Trzecim kierunkiem jest dokładniejsze modelowanie składu. Obecna praca pokazuje, że poziom zawodniczy jest ważniejszy niż sama nazwa drużyny, ale nie wyczerpuje problemu. Można rozważyć cechy opisujące stabilność piątki, liczbę wspólnie rozegranych meczów, zmiany ról, doświadczenie międzynarodowe oraz zgodność stylów gry. Takie cechy mogłyby pomóc odróżnić drużyny złożone z indywidualnie silnych graczy od zespołów rzeczywiście stabilnych taktycznie.

9.5 Podsumowanie dyskusji

Wyniki pracy wskazują, że połączenie rankingów zawodniczych, kontekstu historycznego i prostego regularyzowanego metamodelu może skutecznie przewidywać profesjonalne mecze *League of Legends*. Najważniejsza wartość pracy nie polega na pojedynczym dużym skoku metryki, lecz na spójnym procesie: od systemów rankingowych, przez kontrolę chronologii i metamodelowanie, po końcową kalibrację oraz porównanie z rynkiem. Ograniczenia dotyczą głównie zakresu danych, dryfu czasowego oraz braku części informacji jakościowych. Wnioski należy więc traktować jako dowód skuteczności przyjętej metodologii na historycznej próbie, a nie jako pełne rozwiązanie problemu predykcji esportowej.

Rozdział 10

Zakończenie

10.1 Podsumowanie celu pracy

Celem pracy było zbudowanie i ocena modelu probabilistycznego dla profesjonalnych meczów *League of Legends*. Model miał wykorzystywać informacje dostępne przed meczem, w szczególności systemy rankingowe zawodników i drużyn, historyczny kontekst sportowy oraz format serii. Drugim celem była ocena, czy taki model może osiągać jakość predykcyjną konkurencyjną względem prawdopodobieństw implikowanych przez kursy bukmacherskie.

Zakres pracy był świadomie ograniczony do predykcji probabilistycznej. Kursy bukmacherskie pełniły funkcję benchmarku rynkowego, ale nie analizowano strategii obstawiania, zwrotu finansowego ani zarządzania kapitałem. Dzięki temu głównym kryterium oceny pozostała jakość prawdopodobieństw, przede wszystkim LogLoss.

10.2 Najważniejsze wyniki

Pierwszym istotnym wynikiem jest przewaga rankingów zawodniczych nad rankingami drużynowymi. W kontekście esportsu oznacza to, że aktualny skład lepiej opisuje siłę zespołu niż sama historyczna nazwa organizacji. Najlepszym pojedynczym systemem rankingowym okazał się Player Glicko-2.

Drugim wynikiem jest skuteczność metamodelu W20-Binomial. Połączenie predykcji rankingowych, miar niepewności, historycznych cech kroczących oraz korekty formatu serii poprawiło jakość probabilistyczną względem pojedynczego rankingu. Najlepszym estymatorem dla tego zestawu cech była regularyzowana regresja logistyczna ElasticNet.

Trzecim wynikiem jest przewaga finalnego wariantu Sym-Cal LR-ElasticNet-W20-Binomial. Końcowa symetryzacja kolejności drużyn i kalibracja Platt'a poprawiły surowy wariant regresji logistycznej w sposób niewielki, lecz stabilny. Na wspólnej próbie sportowo-rynkowej model finalny uzyskał najniższy LogLoss spośród analizowanych wa-

riantów i benchmarków.

10.3 Weryfikacja hipotez

Hipoteza pierwsza, zgodnie z którą rankingi zawodnicze osiągają lepszą jakość predykcji niż rankingi drużynowe, została potwierdzona. Wynik ten jest zgodny ze specyfiką *League of Legends*, gdzie transfery i zmiany składów istotnie wpływają na bieżącą siłę drużyny.

Hipoteza druga, dotycząca przewagi metamodelu nad pojedynczym rankingiem, również została potwierdzona. Player Glicko-2 był silnym punktem odniesienia, ale metamodel rankingowo-kontekstowy osiągnął lepsze wartości LogLoss i Brier Score.

Hipoteza trzecia, zakładająca przydatność historycznego kontekstu W20, została potwierdzona w sposób umiarkowany. Cechy kroczące nie zastąpiły ratingów, lecz uzupełniły je o informacje o formie, tempie gry, ekonomii i stylu drużyny.

Hipoteza czwarta, odnosząca się do konkurencyjności względem rynku bukmacherskiego, została potwierdzona na analizowanej próbie. Finalny model uzyskał niższy LogLoss niż Market Open i Market Close, a miesięczny bootstrap blokowy wskazał dodatnie przedziały ufności. Wniosek ten dotyczy jakości predykcyjnej, nie wyniku finansowego.

10.4 Odpowiedź na pytanie badawcze

Odpowiedź na główne pytanie badawcze jest pozytywna. Model oparty na rankingach zawodników, historycznym kontekście drużyn, korekcie formatu serii, symetryzacji predykcji i kalibracji Platt'a może skutecznie przewidywać wyniki profesjonalnych meczów *League of Legends*. Na wspólnej próbie z rynkiem bukmacherskim skalibrowany symetryczny LR-ElasticNet-W20-Binomial osiągnął niższy LogLoss niż benchmarki Market Open i Market Close.

Jednocześnie odpowiedź ta ma ograniczony zakres. Wyniki odnoszą się do danych historycznych, zastosowanej procedury walidacji i meczów posiadających kursy bukmacherskie. Nie stanowią dowodu opłacalności strategii zakładów ani gwarancji utrzymania przewagi w przyszłych sezonach. Najważniejszym rezultatem pracy jest więc pokazanie, że starannie skonstruowany model rankingowo-kontekstowy może stanowić silny i interpretowalny model probabilistyczny dla profesjonalnego esportu.

Bibliografia

- Breiman, Leo (1996). „Stacked Regressions”. W: *Machine Learning* 24.1, s. 49–64.
- Costa, Lincoln M. i in. (2021). „Feature Analysis to League of Legends Victory Prediction on the Picks and Bans Phase”. W: *2021 IEEE Conference on Games (CoG)*, s. 1–5. URL: https://ieee-cog.org/2021/assets/papers/paper_292.pdf (term. wiz. 27.05.2026).
- Do, Tiffany D. i in. (2021). „Using Machine Learning to Predict Game Outcomes Based on Player-Champion Experience in League of Legends”. W: *Proceedings of the 16th International Conference on the Foundations of Digital Games*. DOI: 10.1145/3472538.3472579.
- Elo, Arpad E. (1978). *The Rating of Chessplayers, Past and Present*. Arco Publishing.
- Games of League (2026). *GOL.GG Esports Statistics*. URL: <https://gol.gg/> (term. wiz. 16.05.2026).
- Glickman, Mark E. (1995). *The Glicko System*. Boston University Technical Report.
- (2012). „Example of the Glicko-2 System”. W.
- Gneiting, Tilmann i Adrian E. Raftery (2007). „Strictly Proper Scoring Rules, Prediction, and Estimation”. W: *Journal of the American Statistical Association* 102.477, s. 359–378.
- Guo, Chuan i in. (2017). „On Calibration of Modern Neural Networks”. W: *Proceedings of the 34th International Conference on Machine Learning*, s. 1321–1330.
- Herbrich, Ralf, Tom Minka i Thore Graepel (2007). „TrueSkill: A Bayesian Skill Rating System”. W: *Advances in Neural Information Processing Systems*.
- Hvattum, Lars Magnus i Halvard Arntzen (2010). „Using ELO Ratings for Match Result Prediction in Association Football”. W: *International Journal of Forecasting* 26.3, s. 460–470. DOI: 10.1016/j.ijforecast.2009.10.002. URL: <https://ideas.repec.org/a/eee/intfor/v26yi3p460-470.html> (term. wiz. 24.05.2026).
- Joshy, Vivek (2024). „OpenSkill: A Faster Asymmetric Multi-Team, Multiplayer Rating System”. W: *Journal of Open Source Software* 9.93, s. 5901. DOI: 10.21105/joss.05901. URL: <https://joss.theoj.org/papers/10.21105/joss.05901> (term. wiz. 27.05.2026).
- Junior, Jailson B. S. i Cláudio E. C. Campelo (2023). *League of Legends: Real-Time Result Prediction*. arXiv: 2309.02449 [cs.LG].

- Lin, Lucas (2016). *League of Legends Match Outcome Prediction*. Stanford CS229 Project Report. URL: <https://cs229.stanford.edu/projects2016.html> (term. wiz. 27.05.2026).
- Niculescu-Mizil, Alexandru i Rich Caruana (2005). „Predicting Good Probabilities with Supervised Learning”. W: *Proceedings of the 22nd International Conference on Machine Learning*, s. 625–632.
- OddsPortal (2026). *OddsPortal Historical Odds*. URL: <https://www.oddsportal.com/> (term. wiz. 16.05.2026).
- Thegelström, Claudio (2023). „Utilizing Logistic Regression to Apply the ELO System in Forecasting Premier League Odds”. Degree project in Applied Mathematics and Industrial Economics, first cycle. Stockholm, Sweden: KTH Royal Institute of Technology. URL: <https://kth.diva-portal.org/smash/record.jsf?pid=diva2:1823776> (term. wiz. 24.05.2026).
- Weng, Ruby C. i Chih-Jen Lin (2011). „A Bayesian Approximation Method for Online Ranking”. W: *Journal of Machine Learning Research* 12, s. 267–300.
- Wolpert, David H. (1992). „Stacked Generalization”. W: *Neural Networks* 5.2, s. 241–259.
- Wunderlich, Fabian i Daniel Memmert (2018). „The Betting Odds Rating System: Using Soccer Forecasts to Forecast Soccer”. W: *PLOS ONE* 13.6, e0198668. DOI: 10.1371/journal.pone.0198668. URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC5988281/> (term. wiz. 24.05.2026).
- Zadrozny, Bianca i Charles Elkan (2002). „Transforming Classifier Scores into Accurate Multiclass Probability Estimates”. W: *Proceedings of the Eighth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, s. 694–699.

Spis rysunków

4.1	Liczba meczów sportowych w kolejnych latach w danych GOL.GG.	20
4.2	Liczba pojedynczych gier w kolejnych latach w danych GOL.GG.	20
4.3	Liczba meczów w kolejnych latach z podziałem według formatu serii. . . .	21
4.4	Udział zwycięstw stron meczu w danych sportowych.	22
4.5	Rozkład formatów serii w danych sportowych.	23
4.6	Udział meczów Tier 1 i Tier 2 w pełnej próbie sportowej od 2020 roku oraz we wspólnej próbie z kursami bukmacherskimi.	24
4.7	Porównanie jakości kursów otwarcia i zamknięcia jako benchmarku probabilistycznego.	25
4.8	Jakość predykcji bukmacherów według formatu serii na wspólnej próbie z kursami. Niższy LogLoss oznacza lepszą jakość probabilistyczną.	26
4.9	Średnia marża kursów otwarcia według bukmachera.	27
4.10	Relacja pomiędzy różnicą średniego historycznego GD@15 a rzeczywistym win rate Team 1.	29
6.1	Porównanie jakości rankingów zawodniczych i drużynowych według AUC. .	41
6.2	Porównanie AUC rankingów i benchmarków rynkowych na wspólnej próbie.	42
6.3	Kalibracja wybranych rankingów i benchmarków rynkowych na wspólnej próbie.	42
7.1	Architektura finalnego modelu W20-Binomial. Diagram pokazuje cztery główne grupy informacji wejściowej oraz dwa końcowe etapy postprocesingu: symetryzację predykcji względem kolejności drużyn i kalibrację Platt'a w schemacie expanding-window.	48
7.2	Macierz korelacji głównych sygnałów rankingowych.	49
7.3	Miesięczny bootstrap blokowy różnic LogLoss dostrojonych modeli względem regresji logistycznej ElasticNet.	52
7.4	Miesięczny bootstrap blokowy różnic LogLoss wariantów maskingu względem pełnego modelu kontekstowego.	54
7.5	Porównanie wariantów symetryzacji i kalibracji według LogLoss na wspólnej próbie rynkowej.	56

7.6	Porównanie wariantów symetryzacji i kalibracji według ECE na wspólnej próbie rynkowej.	56
8.1	Porównanie końcowych modeli według LogLoss na wspólnej próbie.	60
8.2	Przedziały ufności dla różnic LogLoss w miesięcznym bootstrapie blokowym względem finalnego modelu symetrycznego i skalibrowanego.	62
8.3	Porównanie końcowych modeli według AUC na wspólnej próbie.	62
8.4	Przewaga finalnego modelu symetrycznego i skalibrowanego nad benchmarkami według formatu serii. Wartości dodatnie oznaczają niższy LogLoss modelu.	63
8.5	Porównanie końcowych modeli według ECE na wspólnej próbie.	65

Spis tabel

3.1	Źródła danych i zbiory pośrednie wykorzystywane w pracy	12
3.2	Podstawowe wielkości analizowanych zbiorów danych	13
3.3	Główne grupy zmiennych sportowych wykorzystywanych w pracy	14
3.4	Główne grupy zmiennych rynkowych wykorzystywanych w pracy	15
3.5	Zakres średnich kursów rynkowych w zbiorze OddsPortal	16
4.1	Struktura poziomu rozgrywek w danych sportowych i w próbie bukmacherskiej	24
4.2	Orientacyjne wyniki benchmarku bukmacherskiego na wspólnej próbce historycznej	25
4.3	Jakość benchmarku bukmacherskiego według formatu serii	26
4.4	Pokrycie danych, marża i jakość predykcyjna kursów otwarcia według bukmachera	27
5.1	Hierarchia metryk wykorzystywanych przy wyborze modelu	35
6.1	Najlepsze konfiguracje rodzin rankingowych na okresie testowym 2024+	40
7.1	Skład finalnego zestawu cech W20-Binomial	47
7.2	Najwyższe wartości VIF dla sygnałów rankingowych	50
7.3	Wpływ długości okna historycznego na jakość metamodelu	51
7.4	Porównanie dostrojonych rodzin modeli W20-Binomial w procedurze walk-forward	51
7.5	Masking i ablacja sygnału Player Glicko-2 w modelu kontekstowym	53
7.6	Ablacja dodania rankingów drużynowych do finalnego wejścia W20-Binomial	53
7.7	Porównanie wariantów symetryzacji i kalibracji na wspólnej próbie rynkowej	55
8.1	Końcowe porównanie finalnego modelu, wariantów pomocniczych i benchmarków rynkowych	60
8.2	Miesięczny bootstrap blokowy różnic LogLoss względem modelu Sym-Cal LR-ElasticNet-W20-Binomial	61
8.3	LogLoss finalnego modelu i benchmarków według formatu serii	64
8.4	Weryfikacja hipotez badawczych	66